

REVISIÓN SISTEMÁTICA OPEN ACCESS

Reconocimiento Emocional Facial mediante Aprendizaje Automático para el Monitoreo Terapéutico en Niños con Trastorno del Espectro Autista: Una revisión sistemática

Jorge Eduardo Castañeda Alban^{1,2} | Christopher Antonio Pillihuamán Santiago¹ | Jhafet Martín Cánepa Maceda¹ | Jomark Pablo Noriega Zapata³ | Juan Orlando Salazar Campos³ | Kenny Disney Neira Neira⁴

¹Facultad de Ingeniería, Universidad San Ignacio de Loyola, Lima, Perú | ²Programa de Doctorado en Informática, Universidad Complutense de Madrid, Madrid, España | ³Facultad de Ingeniería de Sistemas e Informática, Universidad Nacional Mayor de San Marcos, Lima, Perú | ⁴Escuela de Posgrado, Universidad Tecnológica del Perú, Lima, Perú

Correspondence: Jorge Eduardo Castañeda Alban (jorge.castaneda@usil.pe); Christopher Antonio Pillihuamán Santiago (c.pillihuaman@usil.pe); Jhafet Martín Cánepa Maceda (jhafet.canepa@usil.pe); Jomark Pablo Noriega Zapata (jnoriegaz@usil.edu.pe); Juan Orlando Salazar Campos (jsalazarc@usil.edu.pe); Kenny Disney Neira Neira (kneira@usil.edu.pe)

Received: **Revised:** **Accepted:**

Keywords: Trastorno del Espectro Autista | Reconocimiento de Emociones Faciales | Aprendizaje Automático | Aprendizaje Profundo | Aplicaciones Móviles de Salud | Serious Games | Monitoreo Terapéutico | Redes Neuronales Convolucionales

RESUMEN

Los déficits en el reconocimiento emocional facial constituyen una barrera crítica para el monitoreo terapéutico en niños con Trastorno del Espectro Autista (TEA). Esta revisión sistemática sintetiza evidencia sobre sistemas de reconocimiento de expresividad emocional facial basados en aprendizaje automático para el monitoreo terapéutico en niños con TEA. Siguiendo PRISMA 2020, se identificaron 1,915 registros en Scopus, Web of Science e IEEE Xplore; 34 estudios publicados entre 2018 y 2026 fueron incluidos. Las arquitecturas CNN predominan, con accuracy entre 67.8% y 88.0% en datos clínicos genuinos y hasta 99.0% en datasets de Kaggle sin validez clínica verificada. Las limitaciones críticas incluyen representatividad ecológica limitada (11/34, 32.4%), desbalance de clases (9/34, 26.5%) y ausencia de datasets validados en Latinoamérica. Esta revisión establece fundamentos para desarrollar herramientas digitales accesibles y culturalmente adaptadas.

Datasets: No aplicable (revisión sistemática). Todos los datos extraídos están disponibles en el repositorio público GitHub: <https://github.com/Cris223511/systematic-review-data-analysis>. **Licencia del Dataset:** No aplicable.

1 | Introducción

El Trastorno del Espectro Autista (TEA) es una condición del neurodesarrollo que afecta aproximadamente al 1% de la población mundial, caracterizada por déficits persistentes en la comunicación social recíproca y patrones restrictivos de comportamiento [1]. Entre sus manifestaciones centrales, las dificultades en la expresividad emocional facial constituyen uno de los predictores más robustos de desafíos en el desarrollo social, afectando resultados educativos, relaciones con pares y dinámica familiar [2]. Investigaciones con tecnologías de seguimiento ocular documentan que niños con TEA exhiben patrones diferenciales en el procesamiento de rostros emocionales, caracterizados por fijaciones

reducidas en la región ocular y procesamiento fragmentado de la configuración facial [3], alteraciones que correlacionan significativamente con déficits en reconocimiento emocional y teoría de la mente [3, 4, 5]. A pesar de esta evidencia, las intervenciones terapéuticas para niños con TEA muestran variabilidad considerable en accesibilidad y adaptación cultural, particularmente en entornos con recursos limitados, generando una brecha crítica entre la necesidad de monitoreo objetivo y las herramientas disponibles para cubrirla [6].

La convergencia de avances en aprendizaje automático, particularmente en Redes Neuronales Convolucionales (CNN), y la ubicuidad de dispositivos móviles han generado oportunidades

para desarrollar herramientas de monitoreo terapéutico objetivas y escalables para poblaciones pediátricas. Modelos de transfer learning que emplean arquitecturas ResNet-50, EfficientNet y VGGFace han sido aplicados a la adaptación a características individuales dentro del espectro autista mediante ajuste fino con muestras pequeñas [7]. Sin embargo, la literatura revela una paradoja que atraviesa el campo: modelos entrenados en datasets de Kaggle sin validez clínica reportan accuracies de hasta 99.0%, mientras que al aplicarse a expresiones faciales atípicas de niños con TEA el rendimiento cae al 53–74%, evidenciando una brecha de dominio que limita la transferibilidad de estos resultados al contexto terapéutico [8]. Estudios con datos clínicos propios reportan rangos de exactitud entre 67.8% y 88.0%, valores más modestos pero más representativos de las condiciones reales de uso [2, 9, 10]. Sistemas móviles con OpenCV y TensorFlow Lite han sido documentados en entornos naturalistas [11], aunque los estudios publicados exhiben heterogeneidad metodológica significativa en arquitectura, métricas y poblaciones, lo que limita la comparabilidad directa entre enfoques [9].

Para los fines de esta revisión, el monitoreo terapéutico se define operativamente como el seguimiento longitudinal y cuantitativo de la expresividad emocional facial de un niño con TEA a lo largo de sesiones de intervención, mediante el registro automatizado de patrones emocionales sesión a sesión. Este seguimiento permite al terapeuta detectar cambios intraindividuales en la frecuencia, intensidad y variabilidad de expresiones emocionales, evaluar la respuesta a intervenciones específicas y ajustar las estrategias terapéuticas basándose en datos objetivos y reproducibles como complemento a su evaluación clínica integral. El monitoreo terapéutico se distingue explícitamente del diagnóstico de TEA: no determina ni clasifica el nivel de severidad del trastorno, sino que proporciona métricas de progreso terapéutico interpretables por el profesional clínico.

Para garantizar consistencia conceptual a lo largo de este documento, se adoptan las siguientes definiciones operativas. Reconocimiento emocional facial refiere a la capacidad de un sistema computacional de identificar la emoción expresada en el rostro de una persona a partir de imagen o video. Expresividad emocional refiere a las manifestaciones faciales observables de estados afectivos, independientemente de si el sistema las clasifica en categorías discretas. Monitoreo terapéutico se definió operativamente en el párrafo anterior. Detección de TEA refiere a la clasificación binaria (TEA / no TEA) o por nivel de severidad de una condición mediante modelos ML, tarea clínica y computacionalmente distinta del monitoreo terapéutico y explícitamente fuera del alcance de esta revisión, aunque estudios con este enfoque fueron incluidos como contexto comparativo según CI(1).

A pesar de estos avances tecnológicos, la traducción de la investigación a la práctica clínica enfrenta barreras críticas en contextos con recursos limitados. Una proporción significativa de las aplicaciones para TEA requiere acceso constante a Internet, permaneciendo inaccesibles en regiones con infraestructura no confiable [12]. Más aún, el 88% (30 de 34 estudios) se concentra en poblaciones pediátricas menores de 12 años, reflejando un énfasis desproporcionado en intervención temprana [10]. Un hallazgo particularmente grave es que tres estudios fueron retratados entre diciembre 2024 y diciembre 2025 debido al uso de datasets de Kaggle con imágenes de menores recopiladas de internet sin consentimiento parental documentado ni diagnóstico

clínico verificado [1, 13, 14], exponiendo vulnerabilidades éticas fundamentales en la validación de tecnologías para TEA. Además, solo 8 de 34 estudios identificados ofrecen algún nivel de acceso a datos o código [15, 16], y ninguno comparte simultáneamente dataset completo y código fuente, revelando una crisis de reproducibilidad que obstaculiza el progreso científico acumulativo. La brecha más significativa es la ausencia de herramientas diseñadas para el monitoreo terapéutico objetivo. La mayoría de estudios se enfoca en diagnóstico binario o clasificación de severidad [17], tarea clínicamente distinta del seguimiento sesión a sesión de la expresividad emocional que constituye el objeto de esta revisión. La evidencia específica sobre monitoreo de progreso terapéutico en TEA es escasa dentro del corpus identificado, lo que motiva esta revisión como mapeo del panorama existente. Esta brecha es especialmente pronunciada en América Latina, donde no existe evidencia de datasets validados culturalmente ni aplicaciones adaptadas a contextos con conectividad limitada [5, 18]. Esta revisión sistemática aborda esta brecha sintetizando arquitecturas ML, métricas de rendimiento, características de datasets y limitaciones metodológicas de la literatura existente, con el objetivo de establecer fundamentos para herramientas de monitoreo terapéutico culturalmente adaptadas al contexto latinoamericano.

2 | Materiales y Métodos

2.1 | Preguntas de Investigación y Marco Teórico

A partir de las brechas identificadas en la literatura sobre aplicaciones de Aprendizaje Automático (ML) para el reconocimiento de expresividad emocional en niños con TEA, se formularon seis Preguntas de Investigación específicas (RQ1–RQ6) (Tabla 1) que articulan motivaciones metodológicas, orientan las indagaciones y presentan justificaciones científicas. Estas preguntas incorporan métricas de evaluación como precisión, recall, F1-score y Área Bajo la Curva (AUC). Para garantizar un análisis riguroso y sistemático, las preguntas fueron estructuradas siguiendo el marco Población, Intervención, Comparación, Resultado (PICO) adaptado específicamente para revisiones tecnológicas: población (niños con TEA), intervención (sistemas ML móviles), comparación (arquitecturas alternativas), y resultado (métricas de rendimiento y restricciones de implementación).

2.2 | Protocolo y Registro

Esta revisión sistemática fue conducida en conformidad con las directrices PRISMA 2020 para la presentación integral de revisiones sistemáticas. Los datos, código y materiales suplementarios están disponibles públicamente en el repositorio GitHub: <https://github.com/Cris223511/systematic-review-data-analysis>. Se incluyó una lista de verificación PRISMA 2020 completa como material suplementario para facilitar la replicación y la evaluación metodológica.

TABLE 1 | Preguntas de Investigación y Marco Metodológico.

Motivación	Pregunta de Investigación	Justificación
Las arquitecturas CNN muestran variabilidad en exactitud (72–96%) según el diseño, siendo necesario identificar configuraciones óptimas para el monitoreo de expresividad emocional en niños con TEA	¿Qué arquitecturas subyacentes y modelos de aprendizaje automático han sido empleadas para el reconocimiento de expresividad emocional facial en niños con TEA en el contexto del monitoreo terapéutico?	Identificar configuraciones técnicas que orienten el diseño de sistemas optimizados para las características específicas del procesamiento emocional en TEA, en el contexto del monitoreo terapéutico
La heterogeneidad en las métricas reportadas (solo precisión vs. F1-score) limita la comparabilidad entre estudios y dificulta establecer estándares para herramientas de apoyo clínico	¿Qué métricas se emplean para evaluar el rendimiento de los algoritmos, métodos o modelos de reconocimiento emocional?	Establecer estándares de evaluación que faciliten la comparabilidad entre estudios y la validación clínica en contextos terapéuticos reales
Los valores absolutos de métricas varían según el rango de edad pediátrico (primera infancia vs. infancia media vs. adolescencia) y las condiciones de evaluación (laboratorio vs. ecológico)	¿Cuáles son los valores de exactitud, precisión, recall, F1-score y AUC de estos modelos?	Caracterizar los rangos de rendimiento reportados en la literatura para distintos contextos de evaluación, reconociendo que la heterogeneidad metodológica impide comparaciones directas entre estudios
Los conjuntos de datos occidentales (FER-2013, CK+) presentan limitaciones de generalización hacia poblaciones latinoamericanas, requiriendo la identificación de alternativas representativas	¿Qué conjuntos de datos se utilizan para el entrenamiento y validación de modelos, y cuáles son sus limitaciones respecto a la representatividad?	Evaluar las limitaciones de representatividad y generalización de los datasets disponibles, especialmente respecto a la diversidad cultural y fenotípica relevante para el contexto latinoamericano
Las variables de entrada (imagen facial únicamente vs. multimodal) afectan la robustez de la predicción, requiriendo identificar configuraciones óptimas para implementación móvil en sesiones terapéuticas	¿Qué variables de entrada o características utilizan los sistemas de monitoreo de expresividad emocional en niños con TEA durante intervenciones terapéuticas?	Identificar las características de entrada óptimas que equilibren la exactitud del monitoreo con la viabilidad de implementación móvil en entornos con recursos limitados
Las aplicaciones móviles existentes tienen requisitos técnicos (conectividad, hardware) que limitan la accesibilidad en entornos con recursos restringidos como el contexto latinoamericano	¿Qué limitaciones técnicas y metodológicas impiden la implementación de sistemas de ML en entornos con recursos limitados?	Documentar las barreras técnicas, clínicas y de accesibilidad que requieren atención para la traducción efectiva de la investigación en herramientas de apoyo terapéutico funcionales en nuestro contexto

Nota: Esta tabla presenta el marco metodológico completo de la revisión sistemática, articulando las motivaciones teóricas subyacentes a cada pregunta de investigación y sus respectivas justificaciones científicas. Cada pregunta fue estructurada siguiendo el marco PICO adaptado para revisiones tecnológicas, conectando las brechas identificadas en la literatura con los objetivos específicos de síntesis de evidencia orientados al monitoreo de expresividad emocional en contextos terapéuticos.

2.3 | Fuentes de Información y Estrategia de Búsqueda

Se realizaron búsquedas exhaustivas en tres bases de datos indexadas de referencia: IEEE Xplore Digital Library, Scopus y Web of Science Core Collection. El período de búsqueda abarcó desde 2019 hasta 2025 para los registros recuperados mediante la cadena automatizada. Los estudios publicados en 2018 incluidos en el corpus corresponden a trabajos identificados durante el cribado cuyas fechas de publicación oficial preceden al límite inferior de la cadena pero que fueron recuperados porque sus registros indexados en Scopus, WoS e IEEE contenían los términos de búsqueda dentro del período definido; el estudio de 2026 (Cicceri et al. [34]) fue incorporado porque su indexación se completó antes de la fecha de ejecución de la búsqueda el 15 de febrero de 2026. La búsqueda incluyó artículos de revista y actas de congresos en las áreas de ciencias de la computación, ingeniería biomédica e informática médica. El alcance se restringió a publicaciones de acceso abierto con el fin de mejorar la reproducibilidad y accesibilidad de los estudios incluidos. Se reconoce que este criterio introduce un potencial sesgo de publicación hacia estudios con financiamiento institucional para costos de acceso abierto. Las fuentes de literatura gris (preprints, informes técnicos y disertaciones) no fueron exploradas sistemáticamente debido a restricciones de recursos y consideraciones de control de calidad, lo que podría limitar la incorporación de hallazgos emergentes no publicados.

La estrategia de búsqueda fue desarrollada mediante un proceso iterativo que incluyó búsquedas piloto. La cadena prioriza los términos centrales del dominio (reconocimiento emocional facial, aprendizaje automático, TEA) sobre términos de aplicación específica como ‘serious games’ o ‘therapeutic monitoring’, dado que la literatura indexada en estas bases de datos raramente emplea dichos términos como descriptores primarios en títulos y resúmenes. Una búsqueda piloto con términos como ‘serious game AND autism AND emotion’ recuperó menos del 2% de registros adicionales no solapados, confirmando que la cadena principal captura adecuadamente el corpus relevante. Se reconoce, no obstante, que esta decisión puede haber excluido estudios de intervención terapéutica que emplean terminología de gamificación como descriptor principal; esta limitación se documenta explícitamente en la Sección 2.8.

La cadena de búsqueda principal empleada en Scopus fue la siguiente:

Cadena de búsqueda principal (Scopus)

TITLE-ABS-KEY(("autism" OR "ASD" OR "autism spectrum" OR "autistic") AND ("emotion" OR "facial expression" OR "affective" OR "social communication") AND ("machine learning" OR "deep learning" OR "artificial intelligence" OR "computer vision" OR "neural network" OR "classification" OR "recognition")) AND PUBYEAR > 2018

AND PUBYEAR < 2026 AND (LIMIT-TO(DOCTYPE,"ar")
OR LIMIT-TO(DOCTYPE,"cp")) AND (LIMIT-TO(OA,"all")
AND (LIMIT-TO(LANGUAGE,"English"))

Esta cadena fue ejecutada con operadores booleanos equivalentes y códigos de campo en IEEE Xplore y Web of Science el 15 de febrero de 2026. Las cadenas de búsqueda específicas por plataforma se proporcionan en el Material Suplementario S1 (disponible en el repositorio GitHub: <https://github.com/Cris223511/systematic-review-data-analysis>).

2.4 | Criterios de Elegibilidad

Para los fines de esta revisión, la población pediátrica se define como individuos de 0 a 18 años, incluyendo primera infancia (0–5 años), infancia media (6–11 años) y adolescencia (12–18 años).

TABLE 2 | Rangos de Edad de la Población Pediátrica.

Categoría	Rango de Edad
Primera infancia	0–5 años
Infancia media	6–11 años
Adolescencia	12–18 años
Población pediátrica total	0–18 años

Nota: Los rangos de edad fueron definidos siguiendo criterios estandarizados de desarrollo pediátrico, reconociendo que cada etapa presenta características distintivas en el procesamiento emocional y las manifestaciones conductuales del TEA que requieren consideración específica en el diseño de intervenciones tecnológicas de monitoreo terapéutico.

Los criterios de inclusión (CI) fueron los siguientes: (1) estudios centrados en el reconocimiento de expresividad emocional facial mediante aprendizaje automático en niños con TEA, con foco primario en sistemas orientados al monitoreo terapéutico de la expresividad emocional; como contexto comparativo secundario se incluyeron también estudios orientados a detección o clasificación de TEA, exclusivamente para documentar la brecha entre el enfoque diagnóstico predominante en la literatura y el enfoque de monitoreo que motiva esta revisión, con la restricción explícita de que dichos estudios secundarios quedan excluidos de las conclusiones sobre efectividad de herramientas de monitoreo terapéutico y son etiquetados como tal en toda la síntesis; (2) empleo de aplicaciones móviles, sistemas basados en smartphones o tecnologías adaptables a plataformas móviles; (3) reporte de algún resultado cuantitativo de evaluación relevante al diseño del estudio: métricas de clasificación supervisada (ACC, F1, AUC) en estudios ML, medidas de correlación clínica o tamaño del efecto (ICC, Hedges' g, coeficientes de correlación) en estudios clínicos y conductuales, o métricas de usabilidad en estudios de diseño de sistemas; (4) publicación en revistas arbitradas o actas de congresos indexadas en Scimago Journal Rank (SJR) en cuartiles Q1, Q2, Q3 o Q4; (5) disponibilidad como texto completo de acceso abierto; y (6) redactados en inglés.

Los criterios de exclusión fueron: (1) artículos de revisión, revisiones sistemáticas o metaanálisis; (2) estudios sin validación empírica de ningún tipo, es decir, sin reporte de ninguna métrica cuantitativa de evaluación ya sea ML, clínica, correlacional o

de usabilidad; (3) estudios centrados exclusivamente en modalidades no faciales (p. ej., únicamente voz o señales fisiológicas sin análisis facial); y (4) publicaciones duplicadas del mismo dataset o metodología. La aplicación de CI(3) requiere una aclaración metodológica explícita para resolver una aparente inconsistencia: los 12 estudios excluidos durante la revisión de texto completo bajo este criterio correspondían a trabajos que no reportaban ningún tipo de métrica cuantitativa, ni ML ni clínica equivalente. En contraste, los 21 estudios incluidos en el corpus final que no reportan métricas de clasificación supervisada estándar sí presentan métricas apropiadas a su diseño: estudios clínicos reportan tamaños del efecto (Hedges' g = 0.52 en [5]), coeficientes de correlación ($r = 0.619$ en [3]) o coeficientes de confiabilidad inter-evaluador (ICC en [18, 19]); estudios de diseño de sistemas presentan evaluaciones de usabilidad o validación de expertos ([12, 20]). Esta distinción justifica la inclusión de 34 estudios pese a que solo 13 reportan métricas de clasificación supervisada extraíbles, y es consistente con el criterio CI(3) aplicado de forma diferenciada según el tipo de estudio, tal como se documenta en la Tabla 6.

2.5 | Proceso de Selección y Gestión de Datos

Los registros recuperados fueron importados a un gestor de referencias (Mendeley Desktop v1.19.8) y sometidos a eliminación de duplicados mediante algoritmos automatizados complementados con verificación manual. El proceso de selección siguió un enfoque sistemático en dos fases tal como se documenta en el diagrama de flujo PRISMA.




FIGURE 1 | Estrategia de Investigación PRISMA.

Nota: La figura ilustra el proceso completo de identificación, cribado, elegibilidad e inclusión de estudios, desde los 1,915 registros iniciales identificados hasta los 34 estudios finalmente incluidos en la revisión.

En la Fase 1 (cribado por título y resumen), dos revisores evaluaron de forma independiente todos los registros únicos frente a

los criterios de elegibilidad mediante un formulario de cribado estandarizado. En la Fase 2 (revisión de texto completo), los mismos revisores evaluaron de manera independiente los artículos potencialmente elegibles. La confiabilidad entre evaluadores fue monitoreada en ambas fases mediante el coeficiente kappa de Cohen ($\kappa = 0.82$ para la Fase 1; $\kappa = 0.89$ para la Fase 2, indicando acuerdo sustancial a excelente). Las discrepancias se resolvieron mediante discusiones estructuradas y los desacuerdos no resueltos fueron arbitrados por un tercer revisor senior (J.E.C.A.) con experiencia en tecnologías de asistencia e intervenciones para TEA.

Se identificaron 1,915 estudios en las tres bases de datos. Tras la eliminación de 1,002 registros duplicados, quedaron 913 registros para cribado. De estos, 828 fueron excluidos por título y resumen por no ser relevantes al objetivo de la revisión. Los 85 registros restantes fueron evaluados en texto completo, de los cuales 51 fueron excluidos por las siguientes razones: 15 sin acceso a metodología completa, 18 sin reporte de dataset, 12 sin métricas cuantitativas, 4 con tamaño de muestra insuficiente, y 2 con PDF incompleto o corrupto. Finalmente, 34 estudios cumplieron todos los criterios de inclusión y fueron retenidos para la síntesis cualitativa. No se realizaron búsquedas adicionales mediante rastreo de citas o consulta de expertos, por lo que el conjunto de estudios incluidos en la fase de elegibilidad coincide con el total de estudios incorporados a la síntesis ($N = 34$). La Tabla 3 presenta un resumen cuantitativo de la aplicación de los criterios de inclusión y exclusión en todas las fases.

2.6 | Extracción de Datos y Evaluación de Calidad

Los datos fueron extraídos mediante un formulario estandarizado probado en cinco estudios seleccionados aleatoriamente y refinado iterativamente para garantizar consistencia e integridad. Para cada estudio incluido se extrajeron sistemáticamente: (1) información bibliográfica (autores, año, medio de publicación); (2) características de la población del estudio (rango de edad, tamaño de muestra, criterios diagnósticos); (3) especificaciones de arquitectura y modelo de ML; (4) características de entrada y modalidades de datos; (5) conjuntos de datos empleados para entrenamiento y validación; (6) métricas de rendimiento reportadas; (7) características de implementación móvil; y (8) limitaciones y requisitos técnicos reportados.

Con respecto a los tres estudios retractados identificados ([1, 13, 14]), se adoptó la siguiente política uniforme: estos estudios son documentados en el corpus como evidencia de vulnerabilidades éticas críticas en el campo (uso de datasets de menores sin consentimiento verificado), pero son excluidos de todos los análisis cuantitativos de rendimiento, comparaciones arquitectónicas y síntesis de métricas. Su presencia se limita a advertencias éticas en las secciones correspondientes y a la Tabla 16 de distribución temporal, donde se identifican explícitamente como categoría separada para evidenciar su impacto en el volumen de publicación del período 2024–2025.

Para abordar la evaluación formal de calidad metodológica requerida en revisiones sistemáticas rigurosas, se aplicó el Mixed Methods Appraisal Tool (MMAT) versión 2018 como herramienta de evaluación de calidad estandarizada. El MMAT permite evaluar estudios de diseño heterogéneo mediante criterios adaptados al tipo metodológico de cada estudio, lo cual resulta apropiado dado que el corpus incluye estudios cuantitativos de

aprendizaje automático supervisado, estudios clínicos observacionales y estudios de diseño de sistemas. Para cada estudio se evaluaron cinco criterios de calidad con respuesta S (Sí), N (No) o ND (No Determinable): representatividad de la muestra respecto a la población objetivo, adecuación de las medidas para responder la pregunta de investigación, ausencia de sesgo de selección, control de factores de confusión y completitud de los datos de resultado. La evaluación fue realizada de forma independiente por dos revisores y las discrepancias fueron resueltas por consenso. Los resultados se presentan en la Tabla 4.

Para estudios de ML supervisado, el criterio Q1 (representatividad de la muestra) se evaluó considerando si el dataset empleado corresponde a población pediátrica con TEA confirmado clínicamente, o si proviene de fuentes no validadas clínicamente como repositorios web. El criterio Q3 (ausencia de sesgo de selección) se evaluó considerando los protocolos de partición train/test y la existencia de validación cruzada o datasets independientes de prueba. El criterio Q4 (control de factores de confusión) se evaluó considerando si los autores controlaron variables como iluminación, calidad de imagen, edad y nivel de severidad del TEA en sus análisis. Para estudios de diseño de sistemas sin clasificación supervisada, los criterios Q3 y Q4 fueron marcados como ND dado que su diseño no contempla las condiciones de control propias de estudios cuantitativos experimentales. Es necesario señalar una limitación metodológica explícita respecto al uso del MMAT en este corpus: el instrumento no fue diseñado para producir scores agregados comparables entre diseños de investigación sustancialmente distintos, como estudios de ML supervisado, estudios clínicos observacionales y diseños de sistemas. Por esta razón, el score /5 reportado en la Tabla 4 no debe interpretarse como una escala ordinal de calidad comparable entre tipos de estudio diferentes; su utilidad se restringe a identificar dominios específicos de sesgo dentro de cada tipo metodológico y a distinguir estudios con fallas éticas o metodológicas fundamentales (score 0–2/5) de estudios con mayor rigor en su propio dominio (score 4–5/5). La evaluación MMAT se utiliza en esta revisión con ese propósito específico: modular la interpretación de resultados y la traslación clínica de cada estudio, tal como se desarrolla en la Sección VI.B y la Tabla 17, no para comparar la calidad entre estudios de distinta naturaleza metodológica.

2.7 | Métodos de Síntesis

La heterogeneidad del corpus hace necesaria una clasificación funcional explícita que rija toda la síntesis. Esta clasificación no es un artificio posterior a la selección sino el marco estructural que determina qué estudios constituyen evidencia primaria para cada pregunta de investigación, qué estudios aportan contexto comparativo y qué estudios informan el diseño de herramientas terapéuticas. Los 34 estudios se clasifican en cuatro categorías: (1) reconocimiento emocional facial en TEA mediante ML, categoría de evidencia primaria (19 estudios con arquitectura ML identificable orientada a expresividad emocional); (2) detección y clasificación de TEA mediante ML, categoría de contexto comparativo secundario exclusivamente ([7, 17]), empleada para evidenciar la brecha entre el enfoque diagnóstico predominante en la literatura y el enfoque de monitoreo terapéutico que motiva esta revisión, sin que sus resultados constituyan evidencia sobre efectividad de arquitecturas para monitoreo; (3) monitoreo terapéutico y

TABLE 3 | Aplicación de Criterios de Inclusión y Exclusión.

Criterio	Categoría	N	%
<i>Criterios de Inclusión Iniciales</i>			
Actas de congresos	Identificados	38	1.99%
Artículos de revista	Identificados	1,877	98.01%
Subtotal identificados		1,915	100.00%
<i>Criterios de Exclusión Aplicados</i>			
Registros duplicados	Excluidos	1,002	52.32%
Excluidos por título y resumen (irrelevantes)	Excluidos	828	43.24%
Sin acceso a metodología completa	Excluidos	15	0.78%
Dataset no reportado	Excluidos	18	0.94%
Sin métricas cuantitativas	Excluidos	12	0.63%
Tamaño de muestra insuficiente	Excluidos	4	0.21%
PDF incompleto o corrupto	Excluidos	2	0.10%
Subtotal excluidos		1,881	98.23%
Total de estudios incluidos en la revisión sistemática		34	1.78%

Nota: Los criterios de inclusión priorizan estudios con validación empírica cuantitativa publicados en fuentes indexadas de calidad verificable (SJR Q1–Q4). Las razones de exclusión en la fase de texto completo fueron aplicadas de forma jerarquizada siguiendo el orden establecido en el protocolo: (1) acceso a metodología completa, (2) reporte de dataset, (3) métricas cuantitativas, (4) tamaño de muestra, (5) integridad del documento. Cada estudio fue asignado a la primera categoría de exclusión encontrada durante la revisión; las categorías son por tanto mutuamente excluyentes y su suma es trazable al total de 51 estudios excluidos en texto completo. Esta jerarquización garantiza consistencia en la aplicación del protocolo y permite replicar el proceso de selección a partir de la información reportada. Estas razones operacionales complementan los criterios de exclusión formales definidos en la Sección 2.4 y responden a la evaluación práctica de la calidad y completitud documental durante la revisión de texto completo.

sistemas de apoyo clínico, categoría de mayor relevancia traslacional directa ([16, 18, 19]); y (4) estudios clínicos, conductuales y exploratorios sin modelo ML clasificable, categoría de referencia ecológica y clínica (7 estudios: [3, 4, 5, 20, 27, 28, 32]). Las conclusiones orientadas al diseño de herramientas terapéuticas se derivan de las categorías 1, 3 y 4; la categoría 2 aporta únicamente contexto comparativo. Esta clasificación determina la base de análisis de cada RQ y explica la variación en la base N entre preguntas, tal como se documenta en la Tabla 6.

Dada la considerable heterogeneidad en los diseños de los estudios, arquitecturas de ML, conjuntos de datos de evaluación, características de población y métricas de resultado, se determinó que un metaanálisis cuantitativo sería inapropiado y potencialmente engañoso. En su lugar, se realizó una síntesis descriptiva cuantitativa estructurada de las seis preguntas de investigación (Tabla 1). Para cada pregunta, los hallazgos fueron sintetizados mediante descripciones narrativas complementadas con tablas resumen y estadísticas descriptivas (frecuencias, rangos, medianas según corresponda). Al reportar métricas de rendimiento (RQ3), se señalaron explícitamente las diferencias en las condiciones de evaluación (características del Dataset, tamaños de muestra y enfoques de validación) para contextualizar las comparaciones y evitar implicar equivalencia directa entre estudios conducidos bajo condiciones heterogéneas. Todos los valores de métricas reportados deben interpretarse como resúmenes descriptivos del panorama de evidencia actual y no como estimaciones de efecto agrupadas.

2.8 | Limitaciones y Sesgos Potenciales

Esta revisión sistemática presenta diversas limitaciones inherentes a su metodología. En primer lugar, la restricción a tres bases de datos académicas puede haber excluido estudios relevantes indexados en otras fuentes o disponibles únicamente en repositorios de literatura gris, limitando potencialmente la exhaustividad. En segundo lugar, la restricción a publicaciones de

acceso abierto constituye una limitación metodológica significativa: aunque mejora la reproducibilidad, introduce un sesgo de selección sistemático al excluir potencialmente estudios de alto impacto publicados en revistas sin modalidad OA. Este sesgo es particularmente grave considerando que la revisión busca abordar el contexto latinoamericano, donde los estudios provenientes de regiones con menor financiamiento institucional para costos de publicación OA podrían estar subrepresentados. Investigaciones futuras deberían considerar estrategias de búsqueda sin esta restricción para obtener un panorama más completo de la evidencia disponible. En tercer lugar, la restricción al idioma inglés puede resultar en una representación insuficiente de la investigación publicada en otros idiomas. En cuarto lugar, la evaluación de la contribución metodológica durante la revisión de texto completo, aunque estandarizada mediante pruebas piloto y el protocolo de revisión, involucra necesariamente juicio subjetivo informado por la experiencia de los revisores en tecnologías de asistencia y aplicaciones clínicas para TEA. Finalmente, el sesgo de publicación puede haber influido en los hallazgos si estudios con resultados negativos o nulos permanecieron sin publicar, inflando potencialmente las métricas de rendimiento observadas en la literatura.

Adicionalmente, la cadena de búsqueda priorizó términos de ML y reconocimiento emocional sobre términos de intervención terapéutica y gamificación (p. ej., ‘serious game’, ‘game-based intervention’, ‘therapeutic monitoring’, ‘mHealth’). Esta decisión requiere una justificación metodológica explícita dado que el objetivo declarado de la revisión es precisamente el monitoreo terapéutico: las búsquedas piloto con términos como ‘serious game AND autism AND emotion recognition’, ‘therapeutic monitoring AND ASD AND machine learning’ y ‘mHealth AND autism AND facial expression’ recuperaron en conjunto menos del 2% de registros adicionales no solapados con la cadena principal, lo que indica que la literatura de monitoreo terapéutico publicada en las tres bases seleccionadas raramente emplea dichos términos como descriptores primarios en títulos y resúmenes, recurriendo en cambio a la terminología de ML y reconocimiento emocional

TABLE 4 | Evaluación de Calidad Metodológica mediante MMAT.

#	Referencia	Tipo	Q1	Q2	Q3	Q4	Q5	Score	Estado
1	Güngör et al. [1]	Cuant. no aleatorizado	N	N	N	N	N	0/5	Retractado
2	Johnson et al. [2]	Cuant. no aleatorizado	S	S	S	ND	S	4/5	—
3	He et al. [3]	Cuant. descriptivo	S	S	S	S	S	5/5	—
4	Reed et al. [4]	Cuant. descriptivo	S	S	S	S	S	5/5	—
5	Lecciso et al. [5]	Mixto	S	S	S	ND	S	4/5	—
6	Shaik et al. [6]	Cuant. no aleatorizado	ND	S	ND	N	S	3/5	—
7	Ahmad et al. [7]	Cuant. no aleatorizado	N	S	N	N	S	2/5	—
8	El Rhatassi et al. [8]	Cuant. no aleatorizado	ND	S	ND	N	S	3/5	—
9	Radočaj & Martinović [9]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
10	Washington et al. [10]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
11	Sholikah et al. [11]	Cuant. no aleatorizado	ND	S	ND	N	S	3/5	—
12	Levy et al. [12]	Diseño de sistemas	ND	S	ND	ND	ND	2/5	—
13	Mahmood et al. [13]	Cuant. no aleatorizado	N	N	N	N	N	0/5	Retractado
14	Kumar et al. [14]	Cuant. no aleatorizado	N	N	N	N	N	0/5	Retractado
15	Sariyanidi et al. [15]	Cuant. no aleatorizado	S	S	S	N	S	5/5	—
16	Hassan et al. [16]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
17	Alsubai [17]	Cuant. no aleatorizado	N	S	N	N	S	2/5	—
18	Rudovic et al. [18]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
19	Rudovic et al. [19]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
20	Almeida et al. [20]	Diseño de sistemas	ND	S	ND	ND	ND	2/5	—
21	Alam et al. [21]	Cuant. no aleatorizado	ND	S	N	N	S	3/5	—
22	Hwang et al. [22]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
23	Aljbori et al. [23]	Cuant. no aleatorizado	N	S	N	N	S	2/5	—
24	El Rhatassi et al. [24]	Cuant. no aleatorizado	ND	S	ND	N	S	3/5	—
25	Ramachandran et al. [25]	Cuant. no aleatorizado	ND	S	ND	N	S	3/5	—
26	Hosney et al. [26]	Cuant. no aleatorizado	N	S	N	N	S	2/5	—
27	Nagae & Lee [27]	Cuant. descriptivo	S	S	S	ND	S	4/5	—
28	Papaioannou et al. [28]	Cuant. descriptivo	S	S	S	S	S	5/5	—
29	Dapogny et al. [29]	Cuant. descriptivo	S	S	S	S	S	5/5	—
30	Leo et al. [30]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
31	Akin-Bulbul et al. [31]	Cuant. no aleatorizado	S	S	S	ND	S	4/5	—
32	Xu & Ju [32]	Cuant. descriptivo	S	S	S	S	S	5/5	—
33	O'Sullivan et al. [33]	Cuant. no aleatorizado	S	S	S	S	S	5/5	—
34	Cicceri et al. [34]	Cuant. no aleatorizado	S	S	S	ND	S	4/5	—

Nota: S = Sí; N = No; ND = No Determinable. Score indica el número de criterios cumplidos sobre 5. Los tres estudios retractados ([1, 13, 14]) obtienen 0/5 debido a fallos éticos fundamentales en la construcción del dataset que comprometen todos los criterios de calidad. Los estudios con puntuación 2/5 presentan limitaciones metodológicas significativas principalmente en representatividad muestral y control de factores de confusión. Los estudios con puntuación 5/5 cumplen todos los criterios evaluables según la información reportada en sus publicaciones. La columna Estado identifica los estudios formalmente retractados por sus editoriales. Los estudios sin observación se indican con —. Q1: representatividad de la muestra; Q2: adecuación de las medidas; Q3: ausencia de sesgo de selección; Q4: control de factores de confusión; Q5: completitud de los datos de resultado.

que caracteriza la cadena empleada. No obstante, se reconoce que esta decisión introduce un sesgo potencial de sub-representación de estudios de intervención terapéutica que usen gamificación o mHealth como marco principal, lo que constituye una limitación directa de este corpus. Para abordarla, se recomienda que actualizaciones futuras de esta revisión incluyan una búsqueda complementaria en bases de datos especializadas en tecnologías de salud y educación (p. ej., PsycINFO, CINAHL, Cochrane CENTRAL) con cadenas que combinen términos terapéuticos y de gamificación, con el fin de capturar estudios de intervención que puedan no estar indexados predominantemente bajo terminología de ML en las bases de ciencias de la computación empleadas en esta revisión.

3 | Investigación Actual

Los 34 estudios incluidos en esta revisión abordan tareas clínicas y tecnológicas heterogéneas; la clasificación funcional adoptada para orientar la síntesis se describe en la Sección 2.7. La creciente demanda de herramientas tecnológicas para el monitoreo

objetivo de la expresividad emocional en niños con TEA ha impulsado la generación de volúmenes masivos de datos conductuales, fisiológicos y visuales. El análisis de estos datos mediante técnicas de aprendizaje automático permite diseñar modelos con potencial clínico significativo para apoyar las intervenciones terapéuticas [2]. Esta convergencia tecnológica es particularmente evidente en el desarrollo acelerado de aplicaciones móviles y dispositivos portátiles que permiten procesamiento en tiempo real, operación sin conexión en contextos de conectividad limitada, y continuidad terapéutica fuera de entornos clínicos controlados [12]. La proliferación de smartphones con chips de procesamiento neuronal dedicado y la maduración de frameworks como TensorFlow Lite y PyTorch Mobile sugieren que esta tendencia se intensificará en los próximos años [12].

La base de evidencia para aplicaciones de ML en el contexto de TEA se concentra predominantemente en población infantil. Del total de estudios analizados, el 88% (30 de 34 estudios) se enfocó en niños menores de 12 años, mientras que el 12% restante (4 de 34) incluyó participantes fuera del rango de infancia primaria, con algunos estudios extendiendo la muestra a adolescentes o adultos con TEA. Esta concentración refleja tanto el énfasis

clínico en la intervención temprana como la disponibilidad de protocolos estandarizados de evaluación del desarrollo pediátrico. Los marcos metodológicos y los benchmarks de rendimiento documentados provienen de contextos de investigación heterogéneos que incluyen tanto reconocimiento de expresividad emocional como detección de TEA, lo que requiere la clasificación funcional adoptada en la Sección 2.7 para interpretar correctamente los resultados [10].

Distintos grupos de investigación han abordado estos desafíos mediante enfoques de ML que combinan modelos de clasificación con técnicas de interpretabilidad para aproximar sus predicciones al razonamiento clínico [15]. Sin embargo, persisten dificultades con los modelos implementados [9], que generalmente siguen paradigmas de caja negra con interpretabilidad clínica limitada [8]. Estos modelos presentan problemas particularmente en cuanto a la generalización con muestras pequeñas, el desbalance de clases, la multicolinealidad en datos multimodales y la traducción a entornos clínicos con recursos limitados [21]. El desafío radica en desarrollar sistemas que equilibren el poder predictivo con la transparencia, accesibilidad y adaptación cultural necesarias para contextos como el latinoamericano [6].

En la Tabla 5 se resumen los cinco desafíos metodológicos críticos identificados en la literatura, junto con los métodos y técnicas de ML propuestos para abordarlos, documentando las referencias que reportan explícitamente la implementación de estos enfoques. Los enfoques técnicos documentados incluyen: Inteligencia Artificial Explicable (XAI) mediante técnicas como LIME, SHAP y Grad-CAM para la interpretabilidad de modelos; LSTM para el modelado de secuencias temporales; Análisis de Componentes Principales (PCA) y Mínima Redundancia Máxima Relevancia (MRMR) para la selección de características; Técnica de Sobremuestreo de Minorías Sintéticas (SMOTE), Síntesis Adaptativa (ADASYN), Submuestreo Aleatorio (RUS) y Sobremuestreo Aleatorio (ROS) para el balanceo de clases; y validación cruzada K-Fold junto con Transfer Learning para la validación y generalización de modelos. Esta taxonomía evidencia que, aunque existen métodos para mitigar cada limitación individualmente, su aplicación conjunta e integrada en sistemas clínicos robustos sigue siendo un área de desarrollo futuro.

4 | Resultados de la Investigación

Para orientar la lectura de los resultados, la Tabla 6 resume la base de análisis específica empleada en cada pregunta de investigación, dado que distintas RQs operan sobre subconjuntos diferentes del corpus.

4.1 | Respuesta a RQ1: ¿Qué arquitecturas y modelos de aprendizaje automático han sido empleados para el reconocimiento de expresividad emocional facial en niños con TEA?

El análisis de los 19 estudios válidos con arquitectura ML identificable reveló que los autores emplean predominantemente modelos clasificables en dos categorías arquitectónicas según su complejidad: el 73.7% corresponde a modelos no ensamblados (N-Ens) que utilizan arquitecturas individuales, mientras que el 26.3% implementa modelos ensamblados (Ens) que combinan

múltiples clasificadores para mejorar la robustez predictiva mediante votación o apilamiento, tal como se detalla en la Tabla 7. Cabe señalar que los 8 estudios clínicos o conductuales sin componente ML, los 2 estudios de diseño de sistemas sin clasificación supervisada estándar [12, 20], los 2 estudios con modelos ML no orientados al reconocimiento facial o emocional [17, 33], y los 3 estudios retractados por irregularidades éticas fueron excluidos de este análisis, dado que la RQ1 indaga específicamente sobre arquitecturas de aprendizaje automático (ML) aplicadas al reconocimiento emocional facial; incluirlos distorsionaría los porcentajes y comprometería la validez de las comparaciones arquitectónicas. Dentro de los 19 estudios analizados, cuatro corresponden a estudios de detección o screening de TEA incluidos como contexto comparativo secundario según CI(1) ([6, 7, 9, 21]); sus características arquitectónicas se documentan en este análisis para evidenciar la brecha entre el enfoque diagnóstico predominante y el enfoque de monitoreo terapéutico, pero las conclusiones sobre diseño de herramientas se derivan primariamente de los estudios orientados a expresividad emocional y monitoreo, identificados explícitamente en la Tabla 17.

Los modelos se agruparon en cuatro familias según sus principios algorítmicos: CNN / Aprendizaje Profundo (57.9%), que incluye transfer learning con ResNet-50, EfficientNet y VGG [7, 9], arquitecturas híbridas CNN-LSTM [23, 24] y Vision Transformers [8, 9]; ML Tradicional (15.8%), con Random Forest, XGBoost y KNN priorizados por interpretabilidad [16, 31]; Visión por Computador / Eye-tracking (10.5%), centrada en landmarks y patrones de fijación [15, 29]; y Multimodal / Wearable (15.8%), con fusión de fuentes heterogéneas para monitoreo continuo [18, 19].

Entre los modelos no ensamblados, CNN / Aprendizaje Profundo domina con el 42.1%, donde el transfer learning desde ImageNet es la estrategia predominante para compensar el tamaño reducido de muestras clínicas [7, 10]. ML Tradicional y Visión por Computador representan cada uno el 10.5%, persistiendo en escenarios donde la interpretabilidad clínica resulta prioritaria [15].

En cuanto a los modelos ensamblados, la familia CNN / Aprendizaje Profundo fue implementada en configuraciones ensambladas en el 15.8% de los estudios, mediante técnicas de soft-voting entre múltiples arquitecturas CNN [6], fusión de características de tres CNNs con LSTM temporal [24], y optimización mediante Grey Wolf Optimizer sobre arquitecturas híbridas [25]. El ML Tradicional alcanza el 5.3% en configuraciones ensambladas a través de votación mayoritaria entre Random Forest, XGBoost y Extra Trees [16], mientras que la familia Multimodal / Wearable representa el 5.3% mediante la fusión de predicciones de múltiples LSTMs especializados por modalidad combinada con aprendizaje por refuerzo profundo para la selección activa de datos durante sesiones terapéuticas [19].

Los modelos no ensamblados constituyen el enfoque más frecuentemente reportado en la literatura revisada para el reconocimiento de expresividad emocional en TEA. Su prevalencia en el corpus puede asociarse con su menor complejidad computacional, aunque la frecuencia de uso no equivale a superioridad clínica ni garantiza viabilidad de implementación en dispositivos móviles, aspectos que requieren validación específica [11]. No obstante, los estudios más recientes documentan una tendencia emergente hacia sistemas multimodales que integran múltiples fuentes de datos heterogéneas mediante arquitecturas de fusión, alcanzando mejoras en la robustez de clasificación de entre 5% y




FIGURE 2 | Distribución de Estudios que Abordan Desafíos Metodológicos en ML para TEA.
 Nota: La figura presenta un resumen visual de la frecuencia con la que los desafíos metodológicos identificados son abordados explícitamente en los 34 estudios revisados.

TABLE 5 | Desafíos Metodológicos en el Monitoreo de Expresividad Emocional en TEA.

#	Desafío Metodológico	Métodos y Técnicas de ML Propuestos	Estudios (n/34)	Referencias
1	Incertidumbre en clasificación y baja robustez predictiva	CNN, Aprendizaje Profundo Personalizado, LSTM, Autoencoders, Visión por Computador	7	[2, 7, 10, 11, 15, 26, 27]
2	Interpretabilidad limitada de modelos de caja negra	XAI (LIME, SHAP, Grad-CAM), Importancia de Características, Análisis de Atención	3	[2, 8, 21]
3	Pobre generalización en muestras pequeñas	K-Fold Cross-Validation, Grid Search, Random Search, Transfer Learning	3	[4, 9, 25]
4	Multicolinealidad en datos multimodales correlacionados	PCA, MRMR, Regularización L1/L2, Selección de Características	3	[4, 5, 19]
5	Desbalance de clases y sesgos de muestreo	SMOTE, RUS, ROS, ADASYN, Ensemble Learning, Aprendizaje Costo-Sensible	3	[9, 21, 26]

Nota: Los desafíos metodológicos identificados representan limitaciones fundamentales que afectan tanto la validez como la aplicabilidad clínica de los modelos de ML en contextos reales de monitoreo terapéutico. La columna “Estudios” indica el número de estudios (sobre 34) que abordan explícitamente cada desafío; los valores no suman 34 porque un mismo estudio puede abordar múltiples desafíos simultáneamente. Cada desafío está vinculado a las técnicas específicas propuestas en la literatura, aunque la implementación conjunta e integrada de estas soluciones en herramientas de apoyo clínico funcionales permanece como área de desarrollo futuro.

15% respecto a enfoques unimodales, especialmente en casos de alta heterogeneidad fenotípica característica del espectro autista [19]. Esta tendencia es particularmente relevante para el diseño de herramientas de monitoreo terapéutico que requieren operar de manera confiable ante la variabilidad expresiva individual de cada niño sesión tras sesión.

4.2 | Respuesta a RQ2: ¿Qué métricas se emplean para evaluar el rendimiento de los algoritmos, métodos o modelos de reconocimiento emocional?

Se compilaron las métricas reportadas por el modelo principal de cada estudio; cuando no se designó uno explícitamente, se reporta el rango observado. La distribución se presenta en la Figura 5.

Del subconjunto de 13 estudios con métricas de clasificación supervisada extraíbles, la Exactitud (ACC) fue la más frecuente (12 estudios), seguida por F1-score (9 estudios), Precisión (6 estudios), Recall (4 estudios), AUC (3 estudios) y la combinación Sensibilidad/Especificidad (1 estudio). La predominancia de ACC refleja su interpretabilidad directa, aunque resulta insuficiente ante desbalance severo de clases, típico en datos clínicos de TEA. El AUC ofrece ventajas metodológicas en ese contexto al evaluar rendimiento independientemente del umbral de clasificación, pero su uso sigue siendo minoritario en el corpus. La combinación Sensibilidad/Especificidad aparece en estudios orientados a contextos clínicos donde el costo diferencial entre falsos positivos y falsos negativos es relevante para la toma de decisiones terapéuticas [30].

Estos hallazgos indican que la ACC y las métricas derivadas (Precisión, Recall y F1-score) constituyen el estándar de facto

TABLE 6 | Base de Análisis por Pregunta de Investigación.

RQ	Estudios analizados	Criterios de exclusión	N
RQ1	Arquitecturas ML	Excluye 8 sin ML, 2 diseño sist., 2 ML no facial, 3 retractados	19
RQ2	Métricas reportadas	Base total del corpus	34
RQ3	Valores cuantitativos	Solo estudios con métricas supervisadas extraíbles	13
RQ4	Datasets	Base total del corpus	34
RQ5	Características entrada	Base total del corpus	34
RQ6	Limitaciones	Base total del corpus	34

Nota: La variación en la base de análisis entre RQs responde a que cada pregunta indaga aspectos distintos del corpus. RQ1 requiere arquitectura ML identificable; RQ3 requiere métricas de clasificación supervisada extraíbles. Las demás preguntas operan sobre el corpus completo de 34 estudios. Para RQ5, se incluyeron los 34 estudios dado que todos reportan características o modalidades de datos de entrada, independientemente de si implementan un componente ML clasificable. Los 8 estudios clínicos o conductuales aportan información sobre variables de entrada conductuales y fisiológicas relevantes para el diseño de herramientas de monitoreo terapéutico.

TABLE 7 | Distribución de Familias de Modelos por Tipo Arquitectónico.


It.	Familia	Ens	N-E	Tot.	E%	NE%	T%
1	CNN / Aprendizaje Profundo	3	8	11	15.8%	42.1%	57.9%
2	ML Tradicional	1	2	3	5.3%	10.5%	15.8%
3	Visión por Comp. / Eye-track.	0	2	2	0.0%	10.5%	10.5%
4	Multimodal / Wearable	1	2	3	5.3%	10.5%	15.8%
	Total	5	14	19	26.3%	73.7%	100%

Nota: Ens = Ensamblados; N-E = No Ensamblados; Tot. = Total; E% = Ens%; NE% = N-Ens%; T% = Total%. La clasificación refleja diferencias arquitectónicas fundamentales en complejidad computacional y estrategias de predicción. Los modelos no ensamblados fueron los más frecuentemente reportados. Se excluyen 8 estudios sin componente ML, 2 estudios de diseño de sistemas [12, 20], 2 estudios con ML no orientado al reconocimiento facial [17, 33] y 3 retractados, quedando 19 estudios como base.


para la evaluación de modelos de reconocimiento de expresividad emocional en TEA, permitiendo comparaciones entre enfoques metodológicos heterogéneos. Sin embargo, persiste una brecha metodológica crítica: la ausencia de reporte sistemático de intervalos de confianza, significancia estadística de las diferencias entre modelos y análisis de error estratificado por subgrupos demográficos. Estas omisiones limitan la interpretabilidad clínica y la capacidad de metaanálisis cuantitativo de la literatura existente, dificultando además la identificación de rangos de rendimiento referenciales confiables para el diseño de herramientas de monitoreo terapéutico en contextos como el latinoamericano [9, 26].

4.3 | Respuesta a RQ3: ¿Cuáles son los valores de exactitud, precisión, recall, F1-score y AUC de estos modelos?

De los 34 estudios, 13 (38.2%) reportaron métricas cuantitativas de clasificación supervisada extraíbles; los 21 restantes emplearon metodologías cualitativas, diseños clínicos sin métricas

**FIGURE 3** | Distribución de Modelos No Ensamblados por Familia Arquitectónica.

Nota: La figura ilustra la predominancia de arquitecturas CNN / Aprendizaje Profundo en implementaciones no ensambladas, reflejando la tendencia hacia soluciones basadas en transfer learning para el reconocimiento de expresividad emocional en contextos con muestras pequeñas.

**FIGURE 4** | Distribución de Modelos Ensamblados por Familia Arquitectónica.

Nota: La figura detalla las configuraciones ensambladas identificadas, destacando la combinación de clasificadores heterogéneos como estrategia para mejorar la robustez predictiva ante la alta variabilidad fenotípica del espectro autista.

estándar, o fueron excluidos por retracción o ausencia de ML. Los valores de la Tabla 9 no constituyen benchmarks comparables: provienen de estudios con datasets, tareas clínicas y protocolos heterogéneos y deben interpretarse como síntesis descriptiva del panorama actual. A efectos interpretativos se distinguen: (a) estudios con datos clínicos o validez ecológica verificable ([2, 9, 10, 15, 16, 19, 22]), más representativos de condiciones reales de monitoreo; y (b) estudios con datasets de Kaggle de validez clínica comprometida ([23, 25, 26]), cuyos valores elevados no son transferibles al contexto terapéutico.

Los valores de la Tabla 9 no son directamente comparables entre sí. Para contextualizar su interpretación, se organizan a continuación según tipo de dataset y entorno de evaluación, criterios ya establecidos en la Tabla 17. Los estudios con datos clínicos en entorno ecológico o terapéutico real reportan rangos de 67.8% a 95.6% de ACC: Hwang et al. [22] alcanzaron 88.0% en aplicación móvil con 89 niños; Hassan et al. [16] reportaron 95.6% sobre el dataset DREAM con más de 3,000 sesiones de terapia; Johnson et al. [2] reportaron 67.8% en condiciones naturalistas. Estos valores son los más relevantes para el diseño de herramientas de monitoreo por provenir de condiciones comparables a las reales.

TABLE 8 | Métricas Reportadas en 13 Estudios con Datos Cuantitativos de Clasificación Supervisada.

It.	Métrica	N	%	Autores
1	ACC	12	92%	[2, 6, 9, 10, 11, 15, 16, 22, 23, 24, 25, 26]
2	Precisión	6	46%	[6, 34, 22, 23, 25, 26]
3	F1-score	9	69%	[6, 9, 10, 11, 16, 22, 23, 25, 26]
4	Recall	4	31%	[6, 23, 25, 26]
5	AUC	3	23%	[6, 23, 25]
6	Sens./Espec.	1	8%	[30]
7	Otras	15	–	[3, 4, 5, 7, 8, 12, 17, 18, 19, 20, 21, 27, 28, 29, 31]
	Total	50		

Nota: La columna N indica el número de estudios que reportaron cada métrica específica, mientras que el porcentaje corresponde al total de 13 estudios con métricas cuantitativas de clasificación supervisada. Los estudios individuales pueden reportar múltiples métricas simultáneamente, por lo que el total no suma 13. La categoría “Otras” incluye estudios que emplean metodologías cualitativas, métricas especializadas no comparables directamente con la clasificación supervisada estándar, o estudios clínicos sin modelo ML.

TABLE 9 | Métricas de Rendimiento Reportadas por Autor.

It.	Autor	ACC	Prec.	F1	Rec.	AUC
1	Johnson et al. [2]	67.8%	–	–	–	–
2	Shaik et al. [6]	84.0%	84.8%	81.9%	86.2%	92.3%
3	Radočaj & Martinović [9]	80.0%	–	78.9%	–	–
4	Washington et al. [10]	79.1%	–	78.0%	–	–
5	Sholikah et al. [11]	91.0%	–	91.0%	–	–
6	Sariyanidi et al. [15]	83.0%	–	–	–	–
7	Hassan et al. [16]	95.6%	–	92.8%	–	–
8	Rudovic et al. [19]	–	–	–	–	–
9	Hwang et al. [22]	88.0%	91.0%	80.0%	–	–
10	Aljbori et al. [23]	99.0%	98.5%	98.6%	98.7%	99.1%
11	El Rhatassi et al. [24]	53.0%	–	–	–	–
12	Ramachandran et al. [25]	96.5%	–	96.4%	96.2%	96.8%
13	Hosney et al. [26]	97.2%	94.0%	93.0%	97.5%	–

Nota: La tabla presenta los valores de las métricas de rendimiento de los estudios que reportan datos cuantitativos extraíbles. Se reportan los resultados del modelo principal propuesto por los autores. En estudios comparativos sin modelo principal designado, se indica el rango. Los valores de algunos estudios pueden coincidir con el mejor resultado reportado cuando el modelo principal es también el de mejor rendimiento. Los valores vacíos (–) indican que el autor no reportó dicha métrica. Los 21 estudios restantes del corpus total de 34 no reportaron métricas cuantitativas de clasificación supervisada estándar. Todos los valores se expresan en porcentaje. Los valores de [23] y [26] deben interpretarse con cautela dado que emplean datasets de Kaggle con validez clínica comprometida, lo que probablemente infla artificialmente el rendimiento reportado. El estudio [19] reporta métricas ACC y F1 en formato gráfico no extraíble numéricamente, por lo que todas sus celdas aparecen vacías.

Los estudios con datasets clínicos en laboratorio controlado reportan rangos de 79.1% a 83.0%: Washington et al. [10] reportaron 79.1% sobre el dataset CAFÉ pediátrico; Radočaj y Martinović [9] reportaron 80.0% sobre FERAC; Sariyanidi et al. [15] reportaron 83.0% sobre datos clínicos del Children’s Hospital of Philadelphia. Los estudios con datasets públicos de benchmark general reportan mayor variabilidad: Sholikah et al. [11] reportaron 91.0% sobre FER-2013, mientras que El Rhatassi et al. [24] reportaron 53.0% de ACC de validación evidenciando overfitting severo, y El Rhatassi et al. [8] documentaron una caída de 74% a 65% al transferir el mismo modelo de FER-2013 a datos de población autista, ilustrando la brecha de dominio. Finalmente, los estudios con datasets de Kaggle de validez clínica comprometida reportan los valores más altos del corpus: 99.0% [23], 97.2% [26] y 96.5% [25], todos con MMAT 2/5, valores no transferibles al contexto terapéutico. Esta organización confirma que a mayor validez ecológica del dataset, menor el accuracy reportado pero mayor la relevancia traslacional para herramientas de monitoreo en contextos clínicos reales.

4.4 | Respuesta a RQ4: ¿Qué conjuntos de datos se utilizan para el entrenamiento y validación de modelos, y cuáles son sus limitaciones respecto a la representatividad?

Entre los 34 estudios revisados, los datasets empleados pueden categorizarse según su accesibilidad y especificidad de reporte. Al examinar los estudios que identificaron explícitamente datasets con nombre, el análisis reveló una distribución equilibrada entre fuentes públicas y privadas. Considerando la accesibilidad a través de todos los estudios, el 50.0% involucró datasets públicos disponibles a través de repositorios académicos o solicitud directa al autor, empleados principalmente para la validación de nuevas arquitecturas ML mediante comparación con referencias de rendimiento establecidas. Por contraste, el 50.0% empleó datasets privados o de acceso semirrestringido recopilados ad hoc por equipos de investigación específicos, frecuentemente conteniendo datos clínicos sensibles o información propietaria que imposibilita su distribución pública, tal como se ilustra en la Figura 6.

Dentro del subconjunto de estudios revisados, los datasets públicos y privados se distribuyen de manera equilibrada representando cada categoría el 50.0% del total, tal como se detalla en




FIGURE 5 | Métricas de Evaluación Utilizadas en los Estudios Analizados.
 Nota: La figura presenta la distribución de frecuencias de las métricas reportadas en los estudios con datos cuantitativos de clasificación supervisada, evidenciando la predominancia de la exactitud como métrica de referencia y la heterogeneidad en los estándares de reporte.




FIGURE 6 | Distribución de Datasets Públicos versus Privados.
 Nota: La figura ilustra la proporción entre datasets públicos y privados identificados en los 34 estudios revisados, evidenciando la distribución equilibrada entre ambas categorías y la relevancia de los datos clínicos de acceso restringido como barrera para la reproducibilidad y el desarrollo de herramientas de monitoreo terapéutico en contextos con recursos limitados.

la Tabla 10. Esta distribución refleja la tensión entre los principios de ciencia abierta que favorecen la reproducibilidad mediante datasets públicos, y la necesidad práctica de utilizar datos clínicos propietarios que capturan la heterogeneidad real de la población pediátrica con TEA en condiciones naturalistas. Un hallazgo crítico de esta revisión es que los datasets de Kaggle más utilizados, particularmente “Autistic Children Emotions” presente en al menos seis estudios, presentan vulnerabilidades éticas fundamentales al contener imágenes de menores recopiladas de internet sin consentimiento parental verificado ni diagnóstico clínico

TABLE 10 | Distribución de Datasets por Accesibilidad.

Categoría	Estudios	%
<i>Datasets Públicos</i>		
Kaggle ASD / Autistic Children Emotions	6	17.6%
FER-2013	3	8.8%
FERAC	2	5.9%
CK+ (Extended Cohn-Kanade)	1	2.9%
CAFE	1	2.9%
DREAM Dataset	1	2.9%
ABIDE	1	2.9%
Kaggle Screening / Tabulares	1	2.9%
Kaggle FER	1	2.9%
Subtotal Públicos	17	50.0%
<i>Datasets Privados / Semirrestringidos</i>		
Datos clínicos propios (niños ASD)	7	20.6%
Datos de terapia con robot	3	8.8%
Datos de eye-tracking clínicos	2	5.9%
Datasets semipúblicos bajo solicitud	3	8.8%
Datos de ensayo clínico corporativo	1	2.9%
Sin dataset ML identificado	1	2.9%
Subtotal Privados	17	50.0%
Total	34	100.0%

Nota: La tabla desglosa la distribución de estudios según la accesibilidad de los datasets. Estudios con datasets mixtos fueron asignados a la categoría predominante según el componente principal de entrenamiento. Los datasets de Kaggle catalogados como públicos incluyen los conjuntos “Autistic Children Emotions” cuya validez clínica está éticamente comprometida, incluyendo los tres estudios retractados [1, 13, 14], lo que debe considerarse al interpretar los rendimientos reportados. La categoría “Datasets semipúblicos bajo solicitud” incluye AffectNet, JEMImE y ALSPAC, que requieren solicitud formal al autor o institución.

confirmado, lo que originó tres retractaciones entre 2024 y 2025 [1, 13, 14].

Entre los datasets públicos disponibles, FER-2013 fue el más frecuentemente empleado con una prevalencia del 8.8% en los estudios revisados, conteniendo 35,888 imágenes de 48 × 48 píxeles etiquetadas en siete categorías emocionales. Sin embargo, su uso en el contexto de TEA presenta limitaciones críticas de representatividad: fue recopilado exclusivamente de población neurotípica occidental, lo que evidencia una brecha de dominio significativa cuando se aplica a las expresiones faciales atípicas de niños con TEA. Este fenómeno fue documentado directamente por El Rhatassi et al. [8], donde la exactitud cayó de 74% en FER-2013 a 65% al aplicar el mismo modelo a datos de población autista. El dataset FERAC, con imágenes clínicas de niños con TEA del Hospital Ma Shishu en Bangladesh, representa una alternativa metodológicamente más sólida al estar recopilado directamente en población objetivo, aunque su tamaño reducido limita la generalización [9]. La Figura 7 detalla la distribución específica de los datasets más frecuentemente utilizados.

La industria de aplicaciones de salud móvil y los sistemas de monitoreo terapéutico requieren datasets robustos y culturalmente representativos para desarrollar herramientas efectivas en contextos como el latinoamericano. Sin embargo, el acceso a datasets privados con mayor validez clínica está restringido por consideraciones éticas de privacidad bajo normativas como el Reglamento General de Protección de Datos (RGPD) y regulaciones equivalentes en América Latina, limitaciones de propiedad intelectual de equipos de investigación, y la ausencia de infraestructura para compartir datos clínicos sensibles de manera segura [2, 10]. Esta situación es particularmente crítica para el desarrollo de




FIGURE 7 | Datasets Utilizados en los Estudios Revisados.

Nota: La figura presenta la distribución de los datasets identificados en los 34 estudios, diferenciando entre fuentes públicas y privadas, y señalando aquellos con limitaciones éticas o de representatividad que afectan su validez para el diseño de herramientas de monitoreo terapéutico.

herramientas de monitoreo terapéutico en contextos latinoamericanos, donde no existe evidencia de ningún dataset validado que capture la diversidad fenotípica y cultural de la población pediátrica con TEA en la región, representando una brecha fundamental que impide el desarrollo de sistemas de reconocimiento de expresividad emocional culturalmente adaptados para uso terapéutico local.

4.5 | Respuesta a RQ5: ¿Qué variables de entrada o características utilizan los sistemas de monitoreo de expresividad emocional en niños con TEA durante intervenciones terapéuticas?

Los investigadores han propuesto conjuntos heterogéneos de variables de entrada empleando diversos métodos para identificar las características con mayor capacidad predictiva discriminativa. Las técnicas documentadas incluyen: algoritmos de extracción manual de características faciales como Histograma de Gradientes Orientados (HOG), Patrones Binarios Locales (LBP) y Transformada de Características Invariante a la Escala (SIFT); algoritmos de optimización metaheurística para la selección de subconjuntos óptimos de características; métodos estadísticos de reducción de dimensionalidad como PCA y Análisis Discriminante Lineal (LDA); y arquitecturas de aprendizaje profundo que aprenden representaciones jerárquicas de extremo a extremo mediante retropropagación. Los detalles específicos de las categorías de características identificadas se presentan en la Tabla 11.

Para simplificar el análisis comparativo, las variables propuestas se agruparon en seis categorías de alto nivel basadas en su

naturaleza algorítmica, tal como se sintetiza en la Tabla 12 y se visualiza en la Figura 8.

La marcada preferencia por las características faciales para el monitoreo de expresividad emocional en población con TEA se fundamenta en que estas modalidades pueden capturar directamente las manifestaciones visibles de las expresiones emocionales mediante el análisis de configuraciones de Unidades de Acción, detectar microexpresiones transitorias de alta frecuencia que revelan estados afectivos genuinos antes del enmascaramiento social consciente, e identificar patrones atípicos de gaze caracterizados por fijaciones reducidas en la región ocular, constituyendo biomarcadores conductuales robustos y observables durante sesiones de monitoreo terapéutico [15, 30]. Sin embargo, las características faciales aisladas resultan insuficientes para alcanzar un rendimiento clínicamente robusto ante la heterogeneidad fenotípica del espectro autista. Por ello, deben complementarse con arquitecturas CNN adecuadas que capturen dependencias espaciales jerárquicas entre regiones faciales, señales multimodales que incluyan gestos corporales, patrones de movimiento y contexto social situacional de la sesión terapéutica, y técnicas de optimización que permitan una generalización efectiva a poblaciones con la amplia variabilidad individual característica del TEA [16, 19].

4.6 | Respuesta a RQ6: ¿Qué limitaciones técnicas y metodológicas impiden la implementación de sistemas de ML en entornos con recursos limitados?

En los artículos revisados sistemáticamente, los autores identificaron explícitamente las limitaciones metodológicas o problemas

TABLE 11 | Características Específicas Utilizadas.

It.	Grupo	Característica	N	%
1	Características Faciales	Landmarks faciales (68 puntos)	4	11.8%
2	Características Faciales	Unidades de Acción (AU)	3	8.8%
3	Arquitecturas CNN	CNN personalizada / híbrida	3	8.8%
4	Características Faciales	Expresiones emocionales (6–8 clases)	3	8.8%
5	Arquitecturas CNN	Transfer Learning (ResNet, EfficientNet, VGG)	3	8.8%
6	Características Faciales	Patrones de gaze / eye-tracking	2	5.9%
7	Modalidades de Entrada	Frames de video en tiempo real	2	5.9%
8	Características Faciales	Microexpresiones / intensidad expresiva	2	5.9%
9	Arquitecturas CNN	Vision Transformer (ViT, Swin)	2	5.9%
10	Señales Fisiológicas	GSR / EDA / temperatura periférica	1	2.9%
11	Características Faciales	Características geométricas faciales	1	2.9%
12	Modalidades de Entrada	Imágenes de smartphone (ecológicas)	1	2.9%
13	Métodos de Optimización	HOG + selección de características	2	5.9%
14	Señales Fisiológicas	Skeleton 3D + gaze + movimiento de cabeza	1	2.9%
15	Modalidades de Entrada	Video clínico de sesión terapéutica	1	2.9%
16	Señales Fisiológicas	Señales EEG	1	2.9%
17	Otros	Gestos de mano / gesto pointing	2	5.9%
Total			34	100.0%

Nota: Las características se organizan por grupos funcionales que reflejan la naturaleza algorítmica y la modalidad de datos procesada. La prevalencia de características faciales destaca su rol central en el reconocimiento de expresividad emocional durante sesiones terapéuticas, mientras que la diversidad de enfoques evidencia la heterogeneidad metodológica del campo. Los datos suman 34 referencias a características principales identificadas, correspondiendo una característica predominante por estudio incluido en el corpus.




FIGURE 8 | Grupos de Características Utilizadas.

Nota: La figura presenta la distribución de los grupos de características identificados en los 34 estudios incluidos en el corpus, evidenciando la predominancia de las características faciales como modalidad principal para el reconocimiento de expresividad emocional en niños con TEA.

técnicos encontrados durante el diseño, implementación y evaluación de sus sistemas experimentales, aunque existen matices específicos dependientes del contexto en cada caso. Estas limitaciones heterogéneas se consolidaron en seis categorías taxonómicas fundamentales presentadas en la Tabla 13.

La representatividad ecológica limitada, identificada en el 32.4% de los estudios, refiere fundamentalmente a que muchas variables de reconocimiento de expresividad emocional evaluadas en protocolos experimentales de laboratorio controlado no reflejan plenamente la naturaleza dinámica, dependiente del contexto y socialmente situada del comportamiento infantil real durante

TABLE 12 | Grupos de Características.

It.	Grupo de Características	N	%
1	Características Faciales	15	44.1%
2	Arquitecturas CNN	8	23.5%
3	Modalidades de Entrada	4	11.8%
4	Señales Fisiológicas	3	8.8%
5	Métodos de Optimización	2	5.9%
6	Otros	2	5.9%
	Total	34	100.0%

Nota: Los grupos de características representan categorías de alto nivel que consolidan variables específicas basadas en un enfoque algorítmico compartido. La marcada preferencia por las características faciales se fundamenta en su capacidad para capturar directamente las manifestaciones visibles de la expresividad emocional durante sesiones de monitoreo terapéutico, aunque requieren complementación con modalidades adicionales para alcanzar un rendimiento clínicamente robusto ante la variabilidad fenotípica del espectro autista.

TABLE 13 | Limitaciones Identificadas en los Estudios Revisados.

It.	Limitación Identificada	N	%
1	Representatividad ecológica limitada	11	32.4%
2	Desbalance de clases y sesgos de muestreo	9	26.5%
3	Inconsistencia en registro y anotación de datos	6	17.6%
4	Interpretabilidad clínica limitada de modelos	5	14.7%
5	Disponibilidad de datos y proc. centralizado	2	5.9%
6	Adaptabilidad en proc. estructurado/no estructurado	1	2.9%
	Total	34	100.0%

Nota: Las limitaciones categorizadas representan barreras metodológicas y técnicas reportadas explícitamente por los autores en sus publicaciones. La representatividad ecológica limitada emerge como la limitación más prevalente, reflejando la brecha fundamental entre condiciones experimentales controladas y la complejidad dinámica del comportamiento infantil en contextos terapéuticos reales. La interpretabilidad clínica limitada constituye una preocupación crítica adicional, dado que los terapeutas requieren comprender los mecanismos causales subyacentes a las clasificaciones para integrarlas responsablemente en su juicio clínico integral.

sesiones terapéuticas. Las expresiones emocionales faciales típicamente ocurren en secuencias temporales complejas integradas con voz, gestos y contexto social, mientras que los datasets de entrenamiento frecuentemente contienen imágenes estáticas aisladas bajo condiciones de iluminación artificial uniforme y fondos neutros, generando una brecha de validez ecológica que limita la generalización a aplicaciones clínicas reales de monitoreo terapéutico [2, 9].

El desbalance de clases y sesgos de muestreo, reportado en el 26.5% de los estudios, indica que los datasets clínicos de TEA exhiben típicamente un desbalance severo de clases, con proporciones entre 5:1 y 10:1 entre sujetos de desarrollo típico y casos de TEA. Esto reduce significativamente el rendimiento de los modelos al inducir un sesgo hacia la predicción de la clase mayoritaria, que maximiza la exactitud global, pero produce sensibilidad deficiente para la clase minoritaria, factor crítico para la utilidad clínica del sistema en contextos de monitoreo terapéutico donde la detección de patrones expresivos atípicos resulta prioritaria [21, 26].

La inconsistencia en el registro y anotación de datos, observada en el 17.6% de los estudios, refiere a que los registros clínicos existentes han sido anotados manualmente con errores humanos sistemáticos, sesgos de anotación entre múltiples evaluadores y ruido derivado de protocolos de adquisición no estandarizados.

Esto requiere técnicas extensivas de limpieza y preprocesamiento de datos con el riesgo inherente de perder información crítica durante la normalización o de introducir sesgos adicionales mediante decisiones arbitrarias de imputación de valores faltantes [15, 29].

La interpretabilidad clínica limitada de los modelos, identificada en el 14.7% de los estudios, refiere específicamente a la característica inherente de los modelos de aprendizaje profundo como sistemas de caja negra, donde las predicciones emergen de interacciones no lineales complejas entre millones de parámetros distribuidos en múltiples capas ocultas. Esta opacidad algorítmica obstaculiza profundamente la adopción clínica, dado que los terapeutas requieren comprender los mecanismos causales subyacentes a las clasificaciones para integrarlas responsablemente en su juicio clínico integral y comunicarlas éticamente a las familias de los niños atendidos [8, 9].

Para los modelos de reconocimiento de expresividad emocional aplicados específicamente a la población pediátrica con TEA, las dificultades metodológicas se concentran en la consistencia y validez ecológica de la información disponible para entrenamiento y validación, así como en la ausencia total de datasets validados en contextos latinoamericanos. Adicionalmente, la capacidad técnica de los modelos para procesar e integrar coherentemente datos multimodales heterogéneos representa una limitación fundamental: en esta área clínica especializada, la evaluación comprehensiva del progreso terapéutico corresponde necesariamente a la integración sinérgica de múltiples señales complementarias incluyendo expresiones faciales dinámicas, patrones de movimiento corporal atípicos y contexto situacional de la interacción terapéutica [34, 19].

5 | Hallazgos Adicionales

A lo largo de esta revisión sistemática se identificaron técnicas de preprocesamiento y optimización empleadas de manera recurrente en los experimentos analizados. Estos métodos resultan críticos para el rendimiento final de los sistemas de reconocimiento de expresividad emocional aplicados a poblaciones pediátricas con TEA, aunque con frecuencia son reportados de manera fragmentada o con detalle insuficiente en las secciones metodológicas de los estudios.

Las técnicas más prevalentes para la estimación y optimización de hiperparámetros corresponden a la Validación Cruzada K-Fold y la Búsqueda en Cuadrícula (Grid Search), tal como se documenta en la Tabla 14. La Validación Cruzada K-Fold permite una validación robusta mediante particionamiento iterativo de los datos en subconjuntos de entrenamiento y validación, lo cual resulta particularmente crítico en los contextos de muestras pequeñas característicos de la investigación clínica con TEA, donde los datasets típicamente contienen N menor a 100 participantes. La Búsqueda en Cuadrícula explora sistemáticamente el espacio de hiperparámetros para identificar configuraciones óptimas, aunque con un costo computacional elevado que limita su aplicabilidad en espacios de búsqueda de alta dimensionalidad. Los algoritmos más empleados para mitigar el desbalance severo característico de los datasets clínicos de TEA corresponden a la Aumentación de Datos, seguida de SMOTE, Ponderación de Clases y Muestreo Estratificado, tal como se presenta en la

TABLE 14 | Técnicas para la Determinación de Hiperparámetros.

It.	Método	N	%	Autores
1	Validación Cruzada K-Fold	8	23.5%	[6, 7, 9, 10, 16, 21, 24, 25]
2	Grid Search	3	8.8%	[9, 25, 31]
3	Ajuste Manual	4	11.8%	[2, 11, 23, 26]
4	Hold-out Validation	4	11.8%	[6, 15, 34, 22]
5	Optim. Meta-heurística (GWO)	1	2.9%	[25]
6	No especificado	14	41.2%	–
	Total	34	100.0%	

Nota: Los estudios individuales pueden emplear múltiples técnicas simultáneamente, resultando en posible superposición entre categorías. Los porcentajes reflejan la proporción de estudios que documentaron explícitamente cada técnica. La categoría “No especificado” incluye estudios que no reportan estrategias de validación detalladas o emplean enfoques alternativos no clasificables dentro de las técnicas estándar listadas. La Optimización mediante Lobo Gris (GWO) corresponde exclusivamente al estudio [25] que implementa esta técnica metaheurística para la selección de hiperparámetros en la arquitectura GEfficientNet.

Tabla 15. La Aumentación de Datos genera ejemplos sintéticos mediante transformaciones geométricas (rotación, traslación, zoom) y fotométricas (ajuste de brillo y contraste) de imágenes faciales existentes, aumentando artificialmente el tamaño de la clase minoritaria. Por su parte, SMOTE genera instancias sintéticas mediante interpolación lineal entre ejemplos vecinos de las clases minoritarias en el espacio de características, aunque con el riesgo de generar ejemplos poco realistas que no capturan la variabilidad fenotípica real de la expresividad emocional en TEA.

TABLE 15 | Técnicas de Balanceo de Datasets.

It.	Método	N	%	Autores
1	Aumentación de Datos	6	17.6%	[6, 9, 11, 23, 25, 26]
2	SMOTE	2	5.9%	[9, 21]
3	Ponderación de Clases	3	8.8%	[2, 10, 21]
4	Muestreo Estratificado	3	8.8%	[9, 24, 25]
5	Submuestreo Aleatorio (RUS)	1	2.9%	[21]
6	Sin Balanceo Reportado	5	14.7%	[7, 12, 17, 20, 27]
7	No especificado	14	41.2%	–
	Total	34	100.0%	

Nota: Los estudios individuales pueden emplear múltiples técnicas de balanceo simultáneamente, resultando en superposición entre categorías. Los porcentajes se calcularon sobre el total de 34 estudios analizados. La categoría “No especificado” incluye estudios que no reportan explícitamente estrategias de balanceo o abordan el desbalance mediante métodos alternativos no estandarizados.

El reconocimiento de expresividad emocional en TEA puede conceptualizarse como un problema de clasificación supervisada con muestras inherentemente desbalanceadas. Dado que la prevalencia del TEA ronda 1 de cada 36 niños, los estudios con muestras de base poblacional generan inevitablemente datasets donde los casos de desarrollo típico superan a los casos TEA en proporciones que con frecuencia exceden 10:1 [6]. En este contexto, las técnicas de preprocesamiento documentadas en esta revisión constituyen una línea base metodológica para nuevas investigaciones orientadas al monitoreo terapéutico, considerando que la selección apropiada de técnicas de balanceo y optimización de hiperparámetros puede generar mejoras de 10 a 20 puntos

porcentuales en métricas críticas como Recall y F1-score sin modificar la arquitectura subyacente del modelo [21].

6 | Discusión

6.1 | Arquitecturas de Modelos y Tendencias Temporales

Los modelos de aprendizaje automático más implementados para el reconocimiento de expresividad emocional en niños con TEA corresponden a la familia CNN / Aprendizaje Profundo, que representa el 57.9% de las implementaciones con componente ML identificable, tal como se documenta en la Tabla 16 y se visualiza en la Figura 9. Esta distribución refleja la convergencia entre accesibilidad práctica y madurez metodológica: los modelos CNN no ensamblados fueron los más frecuentemente reportados en la literatura revisada. Esta prevalencia puede estar relacionada con su menor costo computacional, aunque la frecuencia de uso no equivale a superioridad clínica ni garantiza viabilidad de implementación en dispositivos móviles [11]. Los modelos que alcanzan los mayores resultados cuantitativos corresponden a configuraciones ensambladas que combinan CNN con LSTM temporal y fusión multimodal, alcanzando exactitudes superiores al 95% en datasets controlados, aunque estos valores deben interpretarse con considerable cautela dado que provienen predominantemente de datasets de Kaggle con validez clínica comprometida [23, 25]. Los estudios con mayor relevancia traslacional para el monitoreo terapéutico, como Hassan et al. [16] y Hwang et al. [22], reportan rangos más modestos (88–95.6%) pero sobre datos clínicos genuinos en contextos de terapia real.

El análisis temporal revela una concentración de productividad entre 2024 y 2025, coincidiendo con la maduración de frameworks de aprendizaje profundo optimizados para dispositivos móviles como TensorFlow Lite y PyTorch Mobile, y la proliferación de smartphones con unidades de procesamiento neuronal dedicadas. Esta concentración temporal refleja la maduración reciente de las tecnologías ML para aplicaciones clínicas y el reconocimiento creciente de las plataformas móviles como vehículos viables para intervenciones terapéuticas continuas fuera de entornos clínicos controlados [12].

Un patrón descriptivo que emerge del análisis del corpus es que los estudios que emplean arquitecturas híbridas CNN-LSTM en configuraciones multimodales reportan valores de F1-score entre 8% y 15% superiores a los reportados por estudios que emplean CNNs individuales [19, 24]. Sin embargo, dado que estos estudios difieren en dataset, población, entorno de evaluación y protocolo de validación, esta diferencia numérica no puede interpretarse como evidencia de superioridad arquitectónica; refleja únicamente que distintas combinaciones de arquitectura, dataset y contexto producen distintos valores de métricas bajo condiciones no controladas de forma equivalente. Lo que sí puede afirmarse descriptivamente es que los estudios con mayor validez ecológica documentada, como Hwang et al. [22], Hassan et al. [16] y Rudovic et al. [19], emplean arquitecturas que integran modelado temporal y fusión multimodal en contextos terapéuticos reales, lo cual constituye una referencia metodológica para el diseño de nuevas herramientas, no una demostración de efectividad comparativa.

TABLE 16 | Tendencias de Familias de Modelos por Año.

It.	Familia	2018	2019	2021	2022	2023	2024	2025	2026	Total
1	CNN / Deep Learning	0	0	0	1	0	5	7	0	13
2	ML Tradicional	0	1	0	0	0	2	0	0	3
3	Visión por Computador / Eye-tracking	1	0	0	0	0	0	1	0	2
4	Multimodal / Wearable	1	1	0	1	0	0	1	1	5
5	Sin modelo ML (clínicos/conceptuales)	0	2	3	0	2	0	1	0	8
6	Retractados	0	0	0	0	0	1	2	0	3
	Total	2	4	3	2	2	8	12	1	34

Nota: La distribución temporal muestra una concentración de productividad entre 2024 y 2025, coincidiendo con la maduración de marcos de trabajo de aprendizaje profundo optimizados para dispositivos móviles y la proliferación de smartphones con unidades de procesamiento neuronal dedicadas. Los estudios sin modelo ML incluyen estudios clínicos, conductuales y de diseño de sistemas sin componente de clasificación supervisada.




FIGURE 9 | Evolución Temporal de las Implementaciones de Familias de Modelos ML (2018–2026).

Nota: La figura visualiza la distribución anual de los 34 estudios incluidos por familia de modelo, evidenciando la aceleración reciente en implementaciones CNN/Deep Learning y la concentración de productividad entre 2024 y 2025.

6.2 | Métricas de Evaluación y Datasets

La tesis metodológica central de esta revisión, sostenida por el análisis conjunto de métricas de rendimiento, evaluación MMAT y tipo de dataset, es la siguiente: existe una correlación inversa sistemática entre el accuracy reportado y la validez clínica y ecológica del estudio, de modo que a mayor validez del dataset y del entorno de evaluación, menor el rendimiento aparente pero mayor la utilidad traslacional al contexto terapéutico real. Esta tesis tiene implicancias directas para el diseño de herramientas de monitoreo terapéutico: un sistema que optimiza accuracy sobre datasets de Kaggle no es necesariamente un mejor candidato para implementación clínica que uno que reporta 15 puntos menos sobre datos pediátricos genuinos en condiciones ecológicas. La evidencia que sostiene esta tesis es la siguiente. De los tres estudios retractados entre 2024 y 2025, Mahmood et al. [13] reportaron 91.33% de ACC con datos de Kaggle sin validez clínica; Güngör et al. [1] reportaron 75.8% con el mismo dataset combinado con FERAC; y Kumar et al. [14] reportaron 79.56% de mAP con imágenes de internet sin diagnóstico verificado; los tres fueron retractados por uso de imágenes de menores sin

consentimiento documentado. Aljbori et al. [23] y Hosney et al. [26], también con datos de Kaggle, reportan valores de 99.0% y 97.2% respectivamente, ambos con MMAT 2/5. En el extremo opuesto, los estudios con mayor validez clínica y ecológica reportan rendimientos entre 67.8% y 88.0%: Hwang et al. [22] alcanzaron 88.0% con 89 niños en condiciones ecológicas reales (MMAT 5/5); Washington et al. [10] reportaron 79.1% de balanced accuracy con el dataset CAFÉ pediátrico (MMAT 5/5); Johnson et al. [2] reportaron 67.8% en condiciones naturalistas con niños con TEA (MMAT 4/5). El patrón es consistente: MMAT 0–2/5 corresponde a accuracy 91–99%, MMAT 4–5/5 corresponde a accuracy 67–88%. Ejemplificando con mayor detalle: Aljbori et al. [23] reportan 99.01% de ACC sobre un dataset de Kaggle de 6 categorías emocionales cuya procedencia ética no está verificada; Hosney et al. [26] reportan 97.2% sobre un dataset creado por una co-autora del mismo estudio, constituyendo un conflicto de interés documentado; El Rhatassi et al. [24] reportan 94.5% de ACC en entrenamiento que colapsa a 53.03% en validación, exponiendo overfitting severo. Esto no es coincidencia metodológica sino reflejo

de que los datos clínicamente válidos capturan la variabilidad real de la expresividad emocional en TEA, que es inherentemente más difícil de clasificar que poses controladas de Kaggle. El desarrollo de herramientas de monitoreo terapéutico debe por tanto priorizar la validez ecológica del dataset sobre la optimización de métricas en laboratorio, aceptando rangos de rendimiento más modestos como consecuencia natural de trabajar con datos clínicamente representativos.

Las métricas de evaluación más prevalentes fueron la Exactitud (ACC), reportada en 12 de 13 estudios (92%); la F1-score, en 9 de 13 estudios (69%); la Precisión, en 6 de 13 estudios (46%); el Recall, en 4 de 13 estudios (31%); y el AUC, en 3 de 13 estudios (23%). Esta distribución puede explicarse por la mayor familiaridad de los investigadores con las métricas estándar de clasificación y la interpretabilidad directa de la ACC para audiencias clínicas. Sin embargo, el AUC ofrece ventajas metodológicas fundamentales en el contexto de desbalance severo de clases al evaluar el rendimiento independientemente del umbral de clasificación seleccionado [9, 26].

Los datasets públicos más utilizados corresponden a FER-2013 (8.8%) y FERAC (5.9%), empleados principalmente para la validación de nuevas arquitecturas mediante comparación con referencias de rendimiento establecidas. Los datasets privados representan el 50.0% de las implementaciones, generando conocimiento a través de aplicaciones en escenarios clínicos específicos que reflejan heterogeneidad real de la población pediátrica con TEA. Una limitación crítica es la ausencia total de datasets públicos que incluyan población pediátrica latinoamericana con TEA, comprometiendo la generalización de modelos entrenados predominantemente en datasets occidentales hacia contextos culturales donde las expresiones emocionales infantiles pueden manifestarse de manera diferente. Además, el 88% de los estudios revisados (30 de 34) se concentró en niños menores de 12 años, indicando la necesidad de ampliar la investigación hacia grupos de edad pediátrica mayor.

Las limitaciones principales identificadas en los datasets corresponden a representatividad ecológica limitada (32.4%), reflejando una brecha entre las condiciones de laboratorio controlado y la variabilidad del contexto real de sesiones terapéuticas; desbalance severo de clases (26.5%), que introduce sesgos predictivos hacia las clases mayoritarias; e inconsistencia en el registro de datos (17.6%) debida a errores de anotación, protocolos no estandarizados y variabilidad entre evaluadores.

La evaluación de calidad metodológica mediante MMAT revela una distribución polarizada en el corpus analizado. Los estudios con mayor rigor metodológico (puntuación 5/5) corresponden predominantemente a investigaciones clínicas con datos propios, muestras clínicamente validadas y protocolos de evaluación controlados ([3, 4, 9, 10, 15, 16, 18, 19, 22, 28, 29, 30, 32, 33]). En contraste, los estudios con puntuaciones bajas (0–2/5) corresponden a los tres retractados y a estudios que emplean datasets de Kaggle sin representatividad clínica verificada, sin control de factores de confusión y con sesgos de selección evidentes. Esta distribución confirma la paradoja accuracy-calidad identificada en RQ3: los estudios con mayor rendimiento reportado tienden a tener menor rigor metodológico, mientras que los estudios con mayor calidad metodológica reportan rendimientos más modestos, pero clínicamente más transferibles. Esta heterogeneidad de calidad debe

considerarse al interpretar cualquier síntesis de la evidencia y reafirmar la necesidad de estándares de reporte más rigurosos en la literatura sobre ML aplicado a TEA.

Esta distribución de calidad incide directamente en la interpretación de los hallazgos de esta revisión. Los resultados de estudios con puntuación 5/5, como Hwang et al. [22], Washington et al. [10], Hassan et al. [16] y Rudovic et al. [18, 19], ofrecen evidencia más sólida para orientar el diseño de herramientas de monitoreo terapéutico, dado que sus metodologías son clínicamente verificables y sus datasets tienen validez ecológica documentada. En contraste, los valores de rendimiento reportados por estudios con puntuación 2/5 o inferior, como Aljbori et al. [23], Hosney et al. [26] y los tres retractados, deben considerarse no transferibles al contexto clínico real. Por tanto, en esta revisión se priorizan los hallazgos de estudios de mayor calidad metodológica al formular implicancias para el diseño de herramientas terapéuticas.

6.3 | Características de Entrada y Limitaciones

Las variables más prevalentes para el reconocimiento de expresividad emocional correspondieron a las Características Faciales (44.1%), las Arquitecturas CNN (23.5%) y las Modalidades de Entrada de video (11.8%), tal como se muestra en las Tablas 11 y 12. Esta distribución indica que las características faciales proporcionan información discriminativa directa sobre las expresiones emocionales, mientras que las arquitecturas CNN permiten la extracción automática de representaciones jerárquicas sin ingeniería manual de características. Sin embargo, las señales fisiológicas complementarias (8.8%) y las características contextuales permanecen subutilizadas a pesar de su potencial para capturar manifestaciones autonómicas de estados emocionales no visibles en expresiones faciales, lo cual es especialmente relevante en TEA, donde la expresión facial no siempre refleja el estado emocional interno del niño [18, 19].

Las limitaciones metodológicas fundamentales identificadas, incluyendo representatividad ecológica limitada (11 de 34, 32.4%), desbalance de clases (9 de 34, 26.5%) e inconsistencia en el registro de datos (6 de 34, 17.6%), constituyen barreras críticas para el desarrollo de herramientas de monitoreo terapéutico efectivas en contextos reales. La ausencia de herramientas diseñadas específicamente para el monitoreo objetivo durante intervenciones clínicas, en contraste con el enfoque predominante en diagnóstico binario de TEA, representa la brecha más significativa identificada en esta revisión para el contexto latinoamericano [7, 17]. La Tabla 17 presenta la síntesis estratificada del corpus completo, integrando tarea clínica, tipo de dataset, entorno de evaluación, calidad metodológica (MMAT) y potencial de traslación al contexto terapéutico para cada uno de los 34 estudios incluidos.

7 | Conclusiones y Líneas Futuras de Investigación

7.1 | Hallazgos Principales y Panorama de Evidencia

Esta revisión sistemática sintetiza exclusivamente evidencia sobre tecnologías de aprendizaje automático aplicadas al reconocimiento de expresividad emocional en niños con TEA (de 0 a 18 años), con una concentración particular en niños menores

TABLE 17 | Síntesis Estratificada del Corpus por Subgrupos Relevantes.

#	Estudio	Tarea clínica	Dataset	Población	Entorno	Arquitectura	Métricas	MMAT
[1]	Güngör et al.	Recon. emocional	Kaggle+FERAC	Niños TEA	Lab.	AutismEfficientNet	ACC 75.8%	0/5
[2]	Johnson et al.	Recon. emocional	AffectNet+clínico	Niños TEA	Ecológico	EfficientNet-v2	ACC 67.8%	4/5
[3]	He et al.	Eye-tracking	Privado (N=42)	Preesc. TEA	Clínico	Eye-tracking	r=0.619	5/5
[4]	Reed et al.	Epidemiológico	ALSPAC (N=3562)	Pediátrico	Poblac.	Regresión	b=-0.18	5/5
[5]	Lecciso et al.	Interv. terapéutica	Privado (N=24)	Niños TEA	Terapia	OpenFace	g=0.52	4/5
[6]	Shaik et al.	Detección TEA	Kaggle ASD	Niños	Lab.	CNN ensamblado	ACC 84%	3/5
[7]	Ahmad et al.	Detección TEA	Kaggle ASD	Niños	Lab.	ResNet50	ACC 92%	2/5
[8]	El Rhatassi 2024	Recon. emocional	FER2013+privado	Adultos autism.	Lab.	CNN vs ViT	ACC 65-74%	3/5
[9]	Radočaj & Mart.	Recon. emocional	FERAC clínico	Niños TEA	Lab.	Swin Transformer	ACC 80%	5/5
[10]	Washington et al.	Recon. emocional	Clínico+CAFE	Niños	Lab./Ecol.	ResNet-152	Bal.ACC 79.1%	5/5
[11]	Sholikah et al.	Recon. tiempo real	FER2013	N=3 TEA	App móvil	VGG-16	ACC 91%	3/5
[12]	Levy et al.	Sistema wearable	FER2013	Adultos TEA	Ecológico	CNN+HW	Sin métricas	2/5
[13]	Mahmood et al.	Detección TEA	Kaggle ASD	Niños	Lab.	ResNet152+ViT	ACC 91.33%	0/5
[14]	Kumar et al.	Detección TEA	Internet	Niños	Lab.	YOLOv7-tiny	mAP 79.56%	0/5
[15]	Sariyanidi et al.	Pred. autismo	Clínico CHOP	Niños TEA+TD	Clínico	Dict.Learning+SVM	ACC ~83%	5/5
[16]	Hassan et al.	Monitor. terapia	DREAM (N=61)	Niños TEA	T. robot	RF+XGBoost+ExtraT.	ACC 95.6%	5/5
[17]	Alsubai	Detección TEA tab.	Kaggle screening	12-36m	Screening	Transformer MDNCT	ACC 94.7%	2/5
[18]	Rudovic 2018	Afecto/terapia	Privado MIT (N=35)	Niños TEA	T. robot	PPA-net	ICC ~60%	5/5
[19]	Rudovic 2019	Active learning	Privado MIT (N=35)	Niños TEA	T. robot	4 LSTMs+Deep RL	Fig.	5/5
[20]	Almeida et al.	Juego serio	Sin dataset ML	TEA 6-12	Juego	RPG (sin ML)	ISO/IEC	2/5
[21]	Alam et al.	Detección TEA	Kaggle+UIFID	Niños	Lab.	ASD-UANet	ACC 96%	3/5
[22]	Hwang et al.	Screening DD	Privado (N=89)	34-77m	App móvil	LSTM+2D-FAN	ACC 88%	5/5
[23]	Aljbori et al.	Recon. emocional	Kaggle	Niños TEA	Lab.	3D-CNN+LSTM	ACC 99%	2/5
[24]	El Rhatassi 2025	Recon. tiempo real	CK++Kaggle	Adultos autism.	Lab.	CNN×3+LSTM	ACC val. 53%	3/5
[25]	Ramachandran et al.	Recon. emocional	Kaggle	Niños	Lab.	GWO-GEfficientNet	ACC 96.5%	3/5
[26]	Hosney et al.	Detección TEA	Kaggle (co-autora)	Niños	Lab.	YOLOv8+DCNN	ACC 97.2%	2/5
[27]	Nagae & Lee	Terapia+EDA	Privado (N=11)	Niños DD	T. robot	EDA+wavelet	Conf. matrix	4/5
[28]	Papaioannou et al.	Carga cogn. EEG	EEG (N=63)	ASD+ADHD	Clínico	MSE+grafos	ANOVA	5/5
[29]	Dapogny et al.	Expr. facial	JEMImE (N=157)	Niños 6-11	Juego clín.	Rand. Forests+PCRF	ACC ~82%	5/5
[30]	Leo et al.	Prod. facial ASD	CK++clínico (N=17)	Niños TEA	Clínico	HOG+SVM+CNN	TP 84.4%	5/5
[31]	Akin-Bulbul et al.	Screening ET	ET privado	Bebés 18-36m	Clínico	KNN+features	ACC 81.45%	4/5
[32]	Xu & Ju	Cerebro VBM	ABIDE (N=203)	TEA 8-12	Clínico	VBM	GMV-ADOS	5/5
[33]	O'Sullivan et al.	Diarización voz	Roche (N=72)	TEA 5-45	Ensayo	Pyannote+ECAPA	r=0.81	5/5
[34]	Cicceri et al.	Gestos pointing	Privado clínico	Niños ASC	Clínico	Framework 4 niv.	mAP 88.6%	4/5

Nota: La tabla presenta la síntesis estratificada de los 34 estudios del corpus según tarea clínica, dataset, población, entorno, arquitectura, métricas y calidad metodológica (MMAT). La traslación clínica de cada estudio se evalúa considerando conjuntamente estos criterios: estudios con MMAT 5/5 y datos clínicos en entorno ecológico o terapéutico real ([2], [5], [9], [10], [15], [16], [18], [19], [22], [27], [29], [30], [34]) presentan alta traslación; estudios con MMAT 0/5 ([1], [13], [14]) tienen traslación nula por retracción independientemente de sus métricas reportadas; los demás estudios presentan traslación media o baja según su tipo de dataset y entorno de evaluación.

de 12 años (88%, 30 de 34 estudios). Todos los valores de métricas de rendimiento reportados deben interpretarse dentro del contexto de heterogeneidad metodológica sustancial entre estudios, incluyendo variaciones en características de los datasets, protocolos de evaluación, rangos de edad específicos dentro de la población pediátrica y condiciones experimentales. Con estas consideraciones contextuales establecidas, se presentan las siguientes conclusiones sustantivas.

Arquitecturas de Modelos. La familia CNN / Aprendizaje Profundo constituye el enfoque más documentado en la literatura con el 57.9% de las implementaciones. Las arquitecturas híbridas que combinan CNN con LSTM y fusión multimodal han sido empleadas principalmente en estudios con datos clínicos de terapia con robot y aplicaciones móviles en condiciones ecológicas, mientras que las CNNs individuales con transfer learning predominan en estudios con datasets públicos de benchmark. Los valores de accuracy más altos del corpus (superiores al 95%) provienen de estudios con datasets de Kaggle con validez clínica comprometida y no son comparables con los valores de estudios clínicos; no constituyen evidencia de superioridad arquitectónica para monitoreo terapéutico. Los estudios con mayor validez ecológica documentada reportan rangos de 67.8% a 88.0% bajo condiciones clínicas

reales, y son estos valores los que ofrecen referencias relevantes para el diseño de herramientas de monitoreo. Adicionalmente, estos modelos presentan desafíos críticos de interpretabilidad clínica y sensibilidad a la heterogeneidad fenotípica del TEA que limitan su implementación directa [16, 19].

Métricas de Evaluación. La ACC predomina como métrica de reporte (12 de 13 estudios), seguida de F1-score (9), Precisión (6), Recall (4) y AUC (3). El AUC resulta metodológicamente más adecuado ante desbalance severo de clases al evaluar el rendimiento independientemente del umbral de clasificación, aunque su adopción sigue siendo minoritaria. No existe evidencia suficiente en el corpus para establecer estándares métricos específicos para el monitoreo terapéutico sesión a sesión [9].

Datasets. Los datasets públicos como FER-2013 (8.8%) y FERAC (5.9%) permiten la validación estandarizada de arquitecturas. Los datasets privados (50.0%) generan conocimiento en contextos clínicos específicos con mayor validez ecológica. Una brecha crítica es la ausencia total de datasets representativos de la población pediátrica latinoamericana con TEA, limitando la generalización transcultural de los modelos desarrollados. El DREAM dataset emerge como el recurso público más robusto

identificado con 61 niños, más de 3,000 sesiones de terapia y más de 300 horas de datos [16].

Características de Entrada. Las características faciales (15 de 34, 44.1%), incluyendo landmarks, unidades de acción, microexpresiones y patrones atípicos de gaze, constituyen las variables predominantes. El rendimiento robusto requiere complementación con CNN optimizadas (8 de 34, 23.5%) y modalidades multimodales (4 de 34, 11.8%) que integren video, señales fisiológicas y datos contextuales de la sesión terapéutica, reflejando la naturaleza multidimensional del procesamiento emocional en TEA [15, 30].

Limitaciones Metodológicas. La representatividad ecológica limitada (11 de 34, 32.4%), el desbalance de datos (9 de 34, 26.5%) y la inconsistencia en el registro (6 de 34, 17.6%) constituyen problemas fundamentales. La Aumentación de Datos (6 de 34, 17.6%) y SMOTE (2 de 34, 5.9%) representan las técnicas de balanceo más documentadas, mientras que la Validación Cruzada K-Fold (8 de 34, 23.5%) y el Ajuste Manual (4 de 34, 11.8%) predominan para la optimización de hiperparámetros.

Técnicas de Preprocesamiento. Las técnicas de balanceo y optimización documentadas constituyen una línea base metodológica crítica, ya que su aplicación apropiada puede facilitar mejoras de 10 a 20 puntos porcentuales en métricas clave sin modificar las arquitecturas subyacentes [21].

7.2 | Líneas Futuras de Investigación

La intervención temprana representa la fase del desarrollo en la que el apoyo intensivo genera el mayor impacto en las trayectorias a largo plazo. Sin embargo, la evidencia actual revela brechas críticas que demandan atención urgente de la comunidad investigadora.

Validación transcultural en poblaciones pediátricas latinoamericanas. Desarrollar y validar datasets que representen niños latinoamericanos con TEA en distintas cohortes de edad. Esto requiere esfuerzos colaborativos multisitio para abordar las variaciones culturales en las normas de expresión emocional infantil, los patrones de comunicación social y los contextos familiares que pueden influir sustancialmente en la generalización de los modelos a poblaciones pediátricas latinoamericanas [6, 10].

Mejora de la validez ecológica. Expandir más allá de las condiciones de laboratorio controlado hacia protocolos de evaluación naturalistas que capturen la complejidad del mundo real durante sesiones terapéuticas reales, incluyendo iluminación variable, contextos sociales diversos, coocurrencia emocional y ruido ambiental. El monitoreo longitudinal mediante evaluaciones ecológicas momentáneas podría proporcionar información sin precedentes sobre las dinámicas temporales del procesamiento emocional y los patrones de respuesta a la intervención terapéutica [2, 18].

Integración de soporte clínico a la decisión. Desarrollar sistemas de IA Explicable (XAI) que proporcionen justificaciones interpretables de las predicciones diseñadas para apoyar, no reemplazar, el juicio clínico del terapeuta. Esto requiere incorporar técnicas como visualización de atención, explicaciones basadas en escenarios alternativos y cuantificación de incertidumbre para que los terapeutas puedan comprender el razonamiento del modelo e integrar los insights algorítmicos en formulaciones clínicas integrales [8, 9].

Intervenciones adaptativas personalizadas. Implementar frameworks de aprendizaje por refuerzo para optimizar estrategias terapéuticas basadas en patrones de respuesta individual capturados mediante monitoreo móvil continuo. Este enfoque podría habilitar trayectorias de intervención verdaderamente personalizadas que se adapten en tiempo real al progreso individual, los desafíos y las necesidades de desarrollo en evolución de cada niño con TEA [19].

Integración multimodal avanzada. Aprovechar arquitecturas Transformer y modelos de lenguaje multimodal para el análisis integrado de flujos de datos heterogéneos, incluyendo imágenes faciales naturalistas, video conductual espontáneo de sesiones terapéuticas y señales vocales de prosodia atípica. Tales enfoques pueden capturar patrones sutiles de expresividad emocional que permanecen indetectables mediante análisis unimodales tradicionales [10].

Concretar este potencial exige articular innovación técnica con validación clínica rigurosa, marcos éticos para la protección de datos de menores y participación directa de terapeutas y familias en el diseño de las herramientas. La prioridad no debería ser la sofisticación del modelo sino su utilidad práctica para el profesional que trabaja con el niño. En el contexto latinoamericano, donde no existe ningún dataset clínicamente validado y los recursos son limitados, estas brechas representan una oportunidad de investigación con relevancia clínica directa para los niños con TEA y sus equipos terapéuticos.

Contribuciones de los Autores

J.E.C.A.: conceptualización, metodología, supervisión, redacción—revisión y edición. C.A.P.S.: curación de datos, análisis formal, redacción—borrador original. J.M.C.M.: curación de datos, análisis formal, redacción—borrador original. J.P.N.Z.: validación, revisión crítica. J.O.S.C.: validación, revisión crítica. K.D.N.N.: supervisión, revisión crítica.

Agradecimientos

Los autores agradecen a las instituciones afiliadas por el apoyo brindado durante el desarrollo de esta revisión sistemática.

Declaración de Financiamiento

Los autores declaran que no recibieron financiamiento externo para la realización de esta investigación.

Conflictos de Interés

Los autores declaran no tener conflictos de interés.

References

1. I. Gungor, A. Sarman, and S. Tuncay. "Can artificial intelligence and face recognition using deep learning detect emotions in children with autism?" *PLoS ONE* 20, no. 12 (2025): e0338701. <https://doi.org/10.1371/journal.pone.0338701>.
2. G. Johnson, V. Argyriou, S. A. Barman, and C. Politis. "Assistive facial expression recognition for children with autism using re-enactment." *Comput Hum Behav Rep* 20 (2025): 100800. <https://doi.org/10.1016/j.chbr.2025.100800>.
3. Y. He et al. "The characteristics of intelligence profile and eye gaze in facial emotion recognition in mild and moderate preschoolers with autism spectrum disorder." *Front Psychiatry* 10 (2019): 402. <https://doi.org/10.3389/fpsy.2019.00402>.

4. Z. E. Reed et al. "Examining the bidirectional association between emotion recognition and social autistic traits using observational and genetic analyses." *J Child Psychol Psychiatry* 62, no. 11 (2021): 1330–1338. <https://doi.org/10.1111/jcpp.13395>.
5. F. Lecciso et al. "Emotional expression in children with ASD: A pre-study on a two-group pre-post-test design comparing robot-based and computer-based training." *Front Psychol* 12 (2021): 678052. <https://doi.org/10.3389/fpsyg.2021.678052>.
6. J. Shaik, R. Shekhar, and C. J. Shelke. "Hybrid deep learning framework for autism detection in children using facial emotion recognition." *Ing Syst Inf* 30, no. 10 (2025): 2595–2607. <https://doi.org/10.18280/isi.301007>.
7. I. Ahmad, J. Rashid, M. Y. Faheem, A. Akram, N. A. Khan, and R. U. Ul Amin. "Autism spectrum disorder detection using facial images: A performance comparison of pretrained convolutional neural networks." *Healthc Technol Lett* 11, no. 4 (2024): 227–239. <https://doi.org/10.1049/htl2.12073>.
8. F. E. El Rhatassi, B. El Ghali, and N. Najima. "Deep learning approaches for recognizing facial emotions on autistic patients." *Int J Electr Comput Eng* 14, no. 4 (2024): 4034–4045. <https://doi.org/10.11591/ijece.v14i4.pp4034-4045>.
9. P. Radočaj, and G. Martinović. "Emotion recognition in autistic children through facial expressions using advanced deep learning architectures." *Appl Sci* 15, no. 17 (2025): 9555. <https://doi.org/10.3390/app15179555>.
10. P. Washington et al. "Improved digital therapy for developmental pediatrics using domain-specific artificial intelligence: Machine learning study." *JMIR Pediatr Parent* 5, no. 2 (2022): e26760. <https://doi.org/10.2196/26760>.
11. R. W. Sholikah, R. V. H. Ginardi, S. L. C. Nugroho, K. Ghazali, and A. S. Indrawanti. "Real-time facial expression recognition to enhance emotional intelligence in autism." *Procedia Comput Sci* 234 (2024): 222–229. <https://doi.org/10.1016/j.procs.2024.02.169>.
12. L. Levy, A. Ambaw, E. Ben-Itzhak, and E. Holdengreber. "A real-time environmental translator for emotion recognition in autism spectrum disorder." *Sci Rep* 14, no. 1 (2024): 31527. <https://doi.org/10.1038/s41598-024-83229-2>.
13. M. A. Mahmood, L. J. Menzli, N. M. Alturki, and M. A. Tawfeek. "Leveraging artificial intelligence for diagnosis of children autism through facial expressions." *Sci Rep* 15, no. 1 (2025): 11945. <https://doi.org/10.1038/s41598-025-96014-6>.
14. A. Kumar, A. Kumar, and D. N. K. Jayakody. "Ambiguous facial expression detection for autism screening using enhanced YOLOv7-tiny model." *Sci Rep* 14, no. 1 (2024): 28501. <https://doi.org/10.1038/s41598-024-77549-6>.
15. E. Sariyanidi, L. D. Yankowitz, R. T. Schultz, J. D. Herrington, B. Tunç, and J. F. Cohn. 2025. "Beyond FACS: Data-driven facial expression dictionaries, with application to predicting autism." In *2025 IEEE 19th Int. Conf. Autom. Face Gesture Recognit. (FG)*, <https://doi.org/10.1109/FG61629.2025.11099288>.
16. I. Hassan, N. Nahid, M. Islam, S. Hossain, B. Schuller, and M. A. R. Ahad. "Automated autism assessment with multimodal data and ensemble learning: A scalable and consistent robot-enhanced therapy framework." *IEEE Trans Neural Syst Rehabil Eng* 33 (2025): 1191–1201. <https://doi.org/10.1109/TNSRE.2025.3546519>.
17. S. Alsubai. "MDNCT: a multi-domain neurocognitive transformer architecture approach for early prediction of autism spectrum disorders." *Sci Rep* 15, no. 1 (2025): 26378. <https://doi.org/10.1038/s41598-025-09862-7>.
18. O. Rudovic, J. Lee, M. Dai, B. Schuller, and R. W. Picard. "Personalized machine learning for robot perception of affect and engagement in autism therapy." *Sci Robot* 3, no. 19 (2018): eaao6760. <https://doi.org/10.1126/scirobotics.aao6760>.
19. O. Rudovic, M. Zhang, B. W. Schuller, and R. Picard. 2019. "Multi-modal active learning from human data: A deep reinforcement learning approach." In *Proc. 2019 Int. Conf. Multi-modal Interact.*, 6–15. <https://doi.org/10.1145/3340555.3353742>.
20. L. M. Almeida et al. "ALTRIRAS: A computer game for training children with autism spectrum disorder in the recognition of basic emotions." *Int J Comput Game Technol* 2019 (2019): 4384896. <https://doi.org/10.1155/2019/4384896>.
21. M. S. Alam, M. M. Rashid, A. J. Bin Haja Mohideen, M. E. E. Alahi, M. Kchaou, and K. A. B. Alharthi. "Robust autism spectrum disorder screening based on facial images (for disability diagnosis): A domain-adaptive deep ensemble approach." *Diagnostics* 15, no. 13 (2025): 1601. <https://doi.org/10.3390/diagnostics15131601>.
22. S. H. Hwang, Y. Yu, J. Kim, T. Lee, Y. R. Park, and H. W. Kim. "A study on the screening of children at risk for developmental disabilities using facial landmarks derived from a mobile-based application." *Psychiatry Investig* 21, no. 5 (2024): 496–505. <https://doi.org/10.30773/pi.2023.0315>.
23. M. A. Aljbori, A. M. Makhlof, and A. Fakhfakh. "A facial emotion recognition system for children with autism, based on the integration of 3D-CNN and LSTM." *J Wirel Mob Netw Ubiquitous Comput Dependable Appl* 16, no. 3 (2025): 433–452. <https://doi.org/10.58346/JOWUA.2025.I3.026>.
24. F. E. El Rhatassi, B. El Ghali, and N. Najima. "Hybrid real time facial emotions recognition on autistic individuals." *Int J Adv Comput Sci Appl* 16, no. 9 (2025): 629–635. <https://doi.org/10.14569/IJACSA.2025.0160959>.
25. R. Ramachandran, R. Malladi, S. Bellamkonda, and E. S. Reddy. "Disorder facial emotion recognition with grey wolf optimized GEfficient-Net for autism spectrum." *Int J Image Graph Signal Process* 17, no. 1 (2025): 1–16. <https://doi.org/10.5815/ijigsp.2025.01.01>.
26. R. Hosney, F. M. Talaat, E. M. El-Gendy, and M. M. Saafan. "AutYOLO-ATT: an attention-based YOLOv8 algorithm for early autism diagnosis through facial expression recognition." *Neural Comput Appl* 36, no. 27 (2024): 17199–17219. <https://doi.org/10.1007/s00521-024-09966-7>.
27. T. Nagae, and J. Lee. "Understanding emotions in children with developmental disabilities during robot therapy using EDA." *Sensors* 22, no. 14 (2022): 5116. <https://doi.org/10.3390/s22145116>.
28. A. Papaioannou et al. "Differences in performance of ASD and ADHD subjects facing cognitive loads in an innovative reasoning experiment." *Brain Sci* 11, no. 11 (2021): 1531. <https://doi.org/10.3390/brainsci11111531>.
29. A. Dapogny et al. "On automatically assessing children's facial expressions quality: A study, database, and protocol." *Front Comput Sci* 1 (2019): 5. <https://doi.org/10.3389/fcomp.2019.00005>.
30. M. Leo et al. "Computational assessment of facial expression production in ASD children." *Sensors* 18, no. 11 (2018): 3993. <https://doi.org/10.3390/s18113993>.
31. I. Akin-Bulbul, I. Kok, and S. Ozdemir. "Otizm belirtilerinin erken tespitinde duygu durumlarına yoneltlen gorsel dikkatin makine ogrenmesi araciligiyla degerlendirilmesi." *Turk Psikoloji Derg* 39, no. SI. <https://doi.org/10.31828/turkpsikoloji.1515430>.
32. M.-X. Xu, and X.-D. Ju. "Abnormal brain structure is associated with social and communication deficits in children with autism spectrum disorder: A voxel-based morphometry analysis." *Brain Sci* 13, no. 5 (2023): 779. <https://doi.org/10.3390/brainsci13050779>.
33. J. O'Sullivan et al. "Automatic speaker diarization for natural conversation analysis in autism clinical trials." *Sci Rep* 13, no. 1 (2023): 10270. <https://doi.org/10.1038/s41598-023-36701-4>.
34. G. Cicceri et al. "AI4ASC: A hierarchical multi-level AI-driven framework for gesture analysis and monitoring in ASC children." *IEEE Access* 14 (2026): 17885–17904. <https://doi.org/10.1109/ACCESS.2026.3659276>.